



南京航空航天大学
NANJING UNIVERSITY OF AERONAUTICS AND ASTRONAUTICS

《大模型安全与知识增强》实验报告

选 题: 03-KnowledgeEditing

题 目: 基于 ROME 与 MEMIT 的大模型知识编辑

院 系: 计算机科学与技术学院/软件学院

专 业: 计算机科学与技术

姓 名: 周金毅

学 号: SC2624011

2026 年 5 月 11 日

1. 实验背景与目的

大语言模型通常以参数形式存储大量事实知识，但这些知识会随时间过期，或在训练阶段即包含错误事实。重新训练或全量微调成本较高，因此知识编辑希望在尽量不影响模型其他能力的前提下，对模型中的特定事实进行快速、定点修改。

本实验的主要目标包括：

- 基于 ROME 完成 10 条自定义事实的单条知识编辑。
- 基于 MEMIT 完成 500 条 ZsRE 样本的一次性批量知识注入。
- 从 ES、PS、NS 三个指标分析编辑效果、泛化能力与局部副作用。
- 完成跨语种泛化 Bonus：用英文注入事实，用中文问题测试模型是否能迁移输出。

2. 实验环境与工具

项目	配置或说明
实验平台	远 程 Linux 服 务 器（CUDA GPU）
基础模型	Qwen/Qwen2.5-0.5B
知识编辑框架	EasyEdit
Python 环境	Python 3.10
核心脚本	baseline.py、edit_rome.py、edit_memit.py、evaluate.py、bonus_cross_lingual.py
自定义数据	data/custom_10.json，包含 10 条事实更新样本
批量数据	data/zsre_500.json，从 ZsRE 中取 500 条样本
结果文件	results/baseline_custom.json、rome_metrics.json、memit_metrics.json、final_metrics.csv、bonus_cross_lingual.json

说明：MEMIT 运行过程中记录的峰值显存来自 torch.cuda.max_memory_allocated，最终峰值显存为 4.72 GB。

3. 数据集与文件格式

3.1 自定义 10 条事实更新数据

自定义数据用于 Task 1 的基线测试与 Task 2 的 ROME 单事实编辑。每条记录包含直接编辑提示、目标答案、旧答案或原始答案、同义改写提示以及局部性测试提示。

字段	含义
case_id	样本编号
subject	被编辑事实的主体
prompt	直接编辑提示词
target_new	希望注入的新事实答案
ground_truth	编辑前旧答案或原始答案
rephrase_prompt	同义改写提示，用于测试泛化性
locality_prompt	无关事实提示，用于测试局部性
locality_ground_truth	无关事实的正确答案

3.2 ZsRE 500 条批量编辑数据

批量编辑任务使用 ZsRE 数据集。实验中下载 zsre_mend_eval.json 后，取前 500 条并转换为本项目统一格式。转换后的数据用于 MEMIT 一次性批量知识注入。

4. Task 1：Baseline Evaluation

本任务在不进行任何知识编辑的情况下，测试原始模型对 10 条目标事实的回答，目的是确认模型存在旧知识、错误知识或知识盲区。

Case	Target New	命中目标答案	命中旧答案	Baseline 输出摘要
custom_001	Linda Yaccarino	否	是	Elon Musk. He is a billionaire and a former CEO of SpaceX (X). He is also a former CEO of Tesl...
custom_002	Sam Altman	是	否	a man named Sam Altman. He is a very smart man who works for a company called OpenAI. OpenAI i...

5. Task 2: ROME 单条事实编辑


ROME（Rank-One Model Editing）通过定位事实相关的中间表示，并对 Transformer 前馈网络中的特定层进行秩一更新，从而实现单条事实的定点写入。本实验使用 EasyEdit 中的 ROME，对 custom_10.json 中的 10 条事实逐一编辑，每条编辑后重置模型权重。

本实验的 ROME 配置使用 Qwen2.5-0.5B 的中后层 FFN 模块作为写入位置，主要参数包括 layers=[12]、v_num_grad_steps=5、v_lr=0.5、rewrite_module_tmp=model.layers.{}.mlp.down_proj。

Case	Target New	ES	PS	NS
custom_001	Linda Yaccarino	60.00%	40.00%	100.00%
custom_002	Sam Altman	100.00%	66.67%	100.00%
custom_003	Satya Nadella	100.00%	75.00%	50.00%
custom_004	Sundar Pichai	100.00%	80.00%	50.00%
custom_005	Mark Zuckerberg	100.00%	50.00%	50.00%
custom_006	Jensen Huang	100.00%	100.00%	50.00%
custom_007	Andy Jassy	100.00%	66.67%	66.67%
custom_008	Neal Mohan	100.00%	66.67%	0.00%
custom_009	Arvind Krishna	100.00%	75.00%	66.67%
custom_010	Bob Iger	100.00%	66.67%	50.00%

ROME 在 10 条自定义事实上的整体结果为 ES=96.00%、PS=68.67%、NS=58.33%。直接编辑成功率较高，说明目标事实能够较有效写入模型；但 PS 明显低于 ES，说明当问题表述从直接 prompt 变为同义改写 prompt 时，模型泛化仍不稳定。NS 只有 58.33%，表明局部性存在一定破坏，无关事实回答可能受到编辑干扰。

edit_rome.py 运行终端输出截图如下。




6. Task 3: MEMIT 批量知识编辑

MEMIT 是 ROME 的批量扩展方法，目标是在一次编辑中写入多条事实知识。本实验使用 ZsRE 前 500 条样本作为批量编辑集，对 Qwen2.5-0.5B 进行一次性知识注入。

项目	结果
批量编辑样本数	500
总耗时	571.27s
峰值显存	4.72 GB
ES	28.62%
PS	26.95%
NS	20.00%

MEMIT 的批量编辑结果明显低于 ROME。可能原因包括：Qwen2.5-0.5B 模型规模较小，参数容量有限；500 条知识同时写入时存在事实之间的相互干扰；ZsRE 样本的目标答案格式复杂，exact match 类指标较严格等。

edit_memit.py 运行终端输出截图如下。



```
MEMIT summary
records: 500
elapsed_seconds: 571.27
peak_memory_gb: 4.722601890563965
(jy) [jyzhou@localhost ~]$ python edit_memit.py

t64(0.0)}`, 'portability': {}, 'rephrase_acc': [np.float64(0.25)]}, 'pre': {'rewrite_acc': [np.float64(0.5)]}, 'portability': {}, 'rephrase_acc': [np.fl
oat64(0.5)]}}
05/11/2026 06:32:33 - INFO - easyeditor.editors.editor - 497 editing: What voice type is Licia Albanese? -> mezzo soprano
{'case_id': 497, 'requested_rewrite': {'prompt': 'What voice type is Licia Albanese?', 'target_new': 'mezzo soprano', 'ground_truth': 'soprano', 'port
ability': {}, 'locality': {'neighborhood': {'prompt': 'The capital of Italy is', 'ground_truth': 'Rome'}}}, 'subject': 'Licia Albanese', 'rephrase_promp
t': 'How was Licia Albanese's range?', 'time': 389.6997194290161, 'post': {'rewrite_acc': [np.float64(0.5)]}, 'locality': {'neighborhood_acc': [np.floa
t64(0.0)]}, 'portability': {}, 'rephrase_acc': [np.float64(0.25)]}, 'pre': {'rewrite_acc': [np.float64(0.5)]}, 'portability': {}, 'rephrase_acc': [np.fl
oat64(0.5)]}}
2026-05-11 06:32:33.497 - easyeditor.editors.editor - INFO - 498 editing: What family does Sporopodium belong? -> Eulophidae
{'case_id': 498, 'requested_rewrite': {'prompt': 'What family does Sporopodium belong?', 'target_new': 'Eulophidae', 'ground_truth': 'Pilocarpaceae',
'portability': {}, 'locality': {'neighborhood': {'prompt': 'The largest planet in the Solar System is', 'ground_truth': 'Jupiter'}}}, 'subject': 'Sporop
odium', 'rephrase_prompt': 'What kind of family belongs to Sporopodium?', 'time': 389.6997194290161, 'post': {'rewrite_acc': [np.float64(0.4)]}, 'local
ity': {'neighborhood_acc': [np.float64(0.0)]}, 'portability': {}, 'rephrase_acc': [np.float64(0.4)]}, 'pre': {'rewrite_acc': [np.float64(0.4)]}, 'portab
ility': {}, 'rephrase_acc': [np.float64(0.4)]}}
05/11/2026 06:32:33 - INFO - easyeditor.editors.editor - 498 editing: What family does Sporopodium belong? -> Eulophidae
{'case_id': 498, 'requested_rewrite': {'prompt': 'What family does Sporopodium belong?', 'target_new': 'Eulophidae', 'ground_truth': 'Pilocarpaceae',
'portability': {}, 'locality': {'neighborhood': {'prompt': 'The largest planet in the Solar System is', 'ground_truth': 'Jupiter'}}}, 'subject': 'Sporop
odium', 'rephrase_prompt': 'What kind of family belongs to Sporopodium?', 'time': 389.6997194290161, 'post': {'rewrite_acc': [np.float64(0.4)]}, 'local
ity': {'neighborhood_acc': [np.float64(0.0)]}, 'portability': {}, 'rephrase_acc': [np.float64(0.4)]}, 'pre': {'rewrite_acc': [np.float64(0.4)]}, 'portab
ility': {}, 'rephrase_acc': [np.float64(0.4)]}}
2026-05-11 06:32:33.683 - easyeditor.editors.editor - INFO - 499 editing: What is the constellation that Horsehead Nebula is a part of? -> Aquarius
{'case_id': 499, 'requested_rewrite': {'prompt': 'What is the constellation that Horsehead Nebula is a part of?', 'target_new': 'Aquarius', 'ground_tr
uth': 'Orion', 'portability': {}, 'locality': {'neighborhood': {'prompt': 'The author of Hamlet is', 'ground_truth': 'William Shakespeare'}}}, 'subject'
: 'Horsehead Nebula', 'rephrase_prompt': 'What is the constellation to which Horsehead Nebula belongs?', 'time': 389.6997194290161, 'post': {'rewrite_a
cc': [np.float64(0.5)]}, 'locality': {'neighborhood_acc': [np.float64(1.0)]}, 'portability': {}, 'rephrase_acc': [np.float64(0.0)]}, 'pre': {'rewrite_a
cc': [np.float64(0.5)]}, 'portability': {}, 'rephrase_acc': [np.float64(0.5)]}}
05/11/2026 06:32:33 - INFO - easyeditor.editors.editor - 499 editing: What is the constellation that Horsehead Nebula is a part of? -> Aquarius
{'case_id': 499, 'requested_rewrite': {'prompt': 'What is the constellation that Horsehead Nebula is a part of?', 'target_new': 'Aquarius', 'ground tr
uth': 'Orion', 'portability': {}, 'locality': {'neighborhood': {'prompt': 'The author of Hamlet is', 'ground_truth': 'William Shakespeare'}}}, 'subject'
: 'Horsehead Nebula', 'rephrase_prompt': 'What is the constellation to which Horsehead Nebula belongs?', 'time': 389.6997194290161, 'post': {'rewrite_a
cc': [np.float64(0.5)]}, 'locality': {'neighborhood_acc': [np.float64(1.0)]}, 'portability': {}, 'rephrase_acc': [np.float64(0.0)]}, 'pre': {'rewrite_a
cc': [np.float64(0.5)]}, 'portability': {}, 'rephrase_acc': [np.float64(0.5)]}}
2026-05-11 06:32:33.683 - easyeditor.editors.editor - INFO - Evaluation took 181.5724585056305
05/11/2026 06:32:33 - INFO - easyeditor.editors.editor -
```

7. Task 4：综合评估

综合评估使用 `evaluate.py` 汇总 ROME 与 MEMIT 的 ES、PS、NS 指标。

方法	数据规模	ES	PS	NS	耗时	峰值显存
ROME	10	96.00%	68.67%	58.33%	-	-
MEMIT	500	28.62%	26.95%	20.00%	571.27s	4.72 GB

指标含义如下：ES（Efficacy Score）表示直接编辑提示下是否输出目标答案；PS（Paraphrase Score）表示同义改写提示下是否仍输出目标答案；NS（Neighborhood/Locality Score）表示无关事实是否保持不变。

从对比结果看，ROME 更适合少量事实的精准编辑，能够取得较高的直接编辑成功率；MEMIT 支持批量注入，但在本实验设置下编辑成功率和局部性都较低，说明批量编辑对模型容量、统计估计和超参数更加敏感。

`evaluate.py` 运行终端输出截图如下。

```
(ke) [jyzhou@localhost llm-knowledge-editing-qwen]$ python evaluate.py \
> --inputs results/rome_metrics.json results/memit_metrics.json \
> --out results/final_metrics.csv
| Method | Records | ES | PS | NS | Time(s) | Peak Mem(GB) |
|-----|-----|-----|-----|-----|-----|-----|
| ROME | 10 | 96.00% | 68.67% | 58.33% | | |
| MEMIT | 500 | 28.62% | 26.95% | 20.00% | 571.2743014236912 | 4.722601890563965 |
(ke) [jyzhou@localhost llm-knowledge-editing-qwen]$ column -s, -t results/final_metrics.csv
method num_records ES PS NS elapsed_seconds peak_memory_gb source
ROME 10 0.96 0.6866666666666668 0.5833333333333334 571.2743014236912 4.722601890563965 results/rome_metrics.json
MEMIT 500 0.2862468253968254 0.26951428571428565 0.2 571.2743014236912 4.722601890563965 results/memit_metrics.json
(ke) [jyzhou@localhost llm-knowledge-editing-qwen]$
```

8. 失败案例与原因分析

8.1 ROME 典型现象

现象	样例	说明
直接编辑不完全成功	custom_001: ES=60.00%, PS=40.00%	Twitter/X CEO 样例中，目标答案 Linda Yaccarino 不能在所有评价 token 上稳定命中。
泛化弱于直接编辑	多数样例 PS < ES	模型对原始英文 prompt 的编辑更明显，但同义改写 prompt 下迁移不足。
局部性破坏	custom_008: NS=0.00%	编辑 YouTube CEO 后，无关事实保持失败，说明局部编辑仍可能扰动相邻知识。

8.2 MEMIT 典型样例

类型	Prompt	Target	ES	PS
成功样例	Who is listed as Thomas of Lancaster, 1st Duke of Clarence father?	Thomas of Lancaster, 1st Duke of Claren...	100.00%	100.00%
成功样例	By which person Lahti Town Hall has been designed?	Aki Kaurismäki	85.71%	85.71%
成功样例	In what war did Svend Poulsen fight in?	War of 1812	85.71%	71.43%
失败样例	What role does Denny Herzig play in football?	winger	0.00%	0.00%
失败样例	What country is Shmavon Shmavonyan from?	Yemen	0.00%	0.00%
失败样例	Which woman was the sister of Claire Clairmont?	Clairmont-Couch	0.00%	0.00%

MEMIT 的失败样例多表现为直接 prompt 和改写 prompt 均无法命中目标答案。原因可能包括批量更新中多个事实的写入方向相互冲突、目标答案过短或实体歧义较强、模型原本缺乏相关背景知识，以及小模型难以同时容纳大量新增事实。

9. Bonus：跨语种泛化测试

进阶挑战选择“跨语种泛化测试”。

实验设计为：使用英文 prompt 与英文目标答案进行 ROME 编辑，然后用中文问题测试模型是否能够输出目标答案或常见中文译名。

指标	结果
样本数	10
编辑前中文命中率	10.00%
编辑后中文命中率	30.00%
新增命中率	20.00%

Case	中文问题	目标答案	编辑前命中	编辑后命中	编辑后输出摘要
custom_001	Twitter (X) 的现任 CEO 是	Linda Yaccarino	否	否	Sandra Y. Yoo, 她于 2013 年 12 月 1 日被任命为 Twitter 的首席执行官, Yoo 于 2
custom_002	OpenAI 的 CEO 是	Sam Altman	否	是	Sam Altman, 他也是 Microsoft 的联合创始人,他也是谷歌的联合创始人,他也是 Facebook 的联合创始人,他也是微软的联合创始人
custom_003	微软的 CEO 是	Satya Nadella	否	否	____ A. 马克·扎克伯格 B. 谷歌创始人拉里·佩奇 C. 谷
custom_004	谷歌的 CEO 是	Sundar Pichai	否	否	埃隆·马斯克, 他也是特斯拉的创始人, 他也是特斯拉的股东, 他也是特斯拉的创始人, 他也是特斯拉的股东, 他
custom_005	Meta 的 CEO 是	Mark Zuckerberg	是	是	____ A. 马克·扎克伯格 B. 基斯·乔布斯 C. 阿里·
custom_006	英伟达的 CEO 是	Jensen Huang	否	是	Jensen Huang, 他也是 NVIDIA 的创始人, 而 NVIDIA 的创始人是 NVIDIA 的创始人是 NVIDIA 的创始人是 NVIDIA 的创始人是 NVIDIA...
custom_007	亚马逊的 CEO 是	Andy Jassy	否	否	杰夫·贝索斯, 他也是亚马逊的创始人杰夫·贝索斯的弟弟, 也是亚马逊的创始人杰夫·贝索斯的
custom_008	YouTube 的 CEO 是	Neal Mohan	否	否	乔·贝兹利 (Jo Bizzarri), 他于 2019 年

- edit_memit.py
- evaluate.py
- bonus_cross_lingual.py
- prepare_zsre_500.py
- data/custom_10.json
- hparams/ROME/qwen2.5-0.5b.yaml
- hparams/MEMIT/qwen2.5-0.5b.yaml
- README.md
- requirements.txt

主要结果文件如下：

- results/baseline_custom.json
- results/rome_metrics.json
- results/memit_metrics.json
- results/final_metrics.csv
- results/bonus_cross_lingual.json
- results/bonus_cross_lingual.csv