

大模型知识编辑实验报告

课程方向：方向 03 - 知识编辑 (Knowledge Editing for LLMs)

实验日期：2026-05-21

基础模型：Qwen/Qwen2.5-0.5B-Instruct

编辑框架：EasyEdit

编辑算法：ROME、MEMIT

1. 实验目标

本实验针对大语言模型中的事实知识更新问题，验证在不重新训练完整模型的情况下，能否使用知识编辑算法修改模型对特定事实的回答。根据方向 03 的任务要求，实验完成以下内容：

- 1. 构建 10 条事实更新数据集，并在未编辑模型上进行 Baseline Evaluation。
- 2. 使用 ROME 对 10 条事实逐条进行单事实编辑。
- 3. 使用 MEMIT 对 CounterFact 中 500 条数据进行批量知识编辑。
- 4. 计算 Efficacy、Generalization、Locality 三类指标，并结合终端输出和失败案例分析实验效果。

2. 实验环境

项目	配置
运行平台	AutoDL GPU 容器
Python	3.10
基础模型	/root/autodl-tmp/models/Qwen2.5-0.5B-Instruct
Transformers	4.45.2
Accelerate	0.34.2
PEFT	0.13.2
编辑框架	EasyEdit
主要脚本	baseline.py, edit_rome.py, edit_memit.py, evaluate.py

实验过程中对 Qwen2.5 与 EasyEdit 做了必要适配：

- mlp_module_tmp 设置为 model.layers.{}.mlp.down_proj。
- lm_head_module 设置为 model.embed_tokens，避免 Qwen2.5 权重共享导致 LookupError: lm_head.weight。
- 对 EasyEdit 的 nethook.py 执行补丁，修复当前 PyTorch 下 forward hook 参数顺序不匹配导致的 Tensor + dict 报错。
- MEMIT 的二阶矩统计数据由 wikipedia 改为 wikitext，并将 mom2_n_samples 调小，以适应 AutoDL 磁盘限制。

3. 数据集

3.1 自定义事实数据集

Task 1 和 Task 2 使用 data/facts_10.json 中的 10 条事实更新数据。每条记录包含：

- prompt：直接编辑提示词。
- target_new：希望模型输出的新事实。
- ground_truth：旧事实或过期事实。
- rephrase_prompt：同义改写提示词，用于测试泛化性。
- locality_prompt 与 locality_ground_truth：无关事实，用于测试局部性。

ID	Subject	Target New	Ground Truth
disney_ceo_2026	Disney	Josh D'Amaro	Bob Iger
us_president_2025	the United States	Donald Trump	Joe Biden
canada_pm_2025	Canada	Mark Carney	Justin Trudeau
uk_pm_2024	the United Kingdom	Keir Starmer	Rishi Sunak
mexico_president_2024	Mexico	Claudia Sheinbaum	Andres Manuel Lopez Obrador
intel_ceo_2025	Intel	Lip-Bu Tan	Pat Gelsinger
starbucks_ceo_2024	Starbucks	Brian Niccol	Laxman Narasimhan
nike_ceo_2024	Nike	Elliott Hill	John Donahoe
boeing_ceo_2024	Boeing	Kelly Ortberg	Dave Calhoun
spotify_ceo_2025	Spotify	Gustav Soderstrom and Alex Norstrom	Daniel Ek

3.2 MEMIT 批量编辑数据

Task 3 使用 CounterFact 数据集前 500 条作为批量编辑集。脚本 edit_memit.py 会将 CounterFact 中的 requested_rewrite 转换为统一格式，并使用固定 locality prompt：

The capital city of France is

对应 locality ground truth 为：

Paris

4. 实验流程与终端输出

4.1 Task 1: Baseline Evaluation

运行命令：

```
python baseline.py \  
  --data data/facts_10.json \  
  --model /root/autodl-tmp/models/Qwen2.5-0.5B-Instruct \  
  --local-files-only
```

输出文件：

```
results/baseline_20260521_151151.json
```

终端输出截图：

```
(editing) root@autodl-container-e07941848a-564391cf:~/autodl-tmp/final# python baseline.py \
--data data/facts_10.json \
--model /root/autodl-tmp/models/Qwen2.5-0.5B-Instruct \
--local-files-only
/root/autodl-tmp/conda/envs/editing/lib/python3.10/site-packages/transformers/generation/configuration_utils.py:601: UserWarning: `do_sample` is set to `False`. However, `temperature` is set to `0.7` -- this flag is only used in sample-based generation modes. You should set `do_sample=True` or unset `temperature`.
  warnings.warn(
/root/autodl-tmp/conda/envs/editing/lib/python3.10/site-packages/transformers/generation/configuration_utils.py:606: UserWarning: `do_sample` is set to `False`. However, `top_p` is set to `0.8` -- this flag is only used in sample-based generation modes. You should set `do_sample=True` or unset `top_p`.
  warnings.warn(
/root/autodl-tmp/conda/envs/editing/lib/python3.10/site-packages/transformers/generation/configuration_utils.py:623: UserWarning: `do_sample` is set to `False`. However, `top_k` is set to `20` -- this flag is only used in sample-based generation modes. You should set `do_sample=True` or unset `top_k`.
  warnings.warn(
Starting from v4.46, the `logits` model output will have the same type as the model (except at train time, where it will always be FP32)
Wrote baseline results to results/baseline_20260521_151151.json
```

Task 1 记录了原始模型在编辑前对 10 条事实的回答。例如在 Intel CEO 样例中，目标答案为 Lip-Bu Tan，但原始模型输出仍包含旧事实 Pat Gelsinger，说明模型存在过期知识。

4.2 Task 2: ROME 单条事实编辑

运行命令：

```
python edit_rome.py \
  --data data/facts_10.json \
  --hparams hparams/ROME/qwen2.5-0.5b.yaml \
  --model /root/autodl-tmp/models/Qwen2.5-0.5B-Instruct
```

输出文件:

results/rome_20260521_151411.json

终端输出截图：

```
(editing) root@autodl-container-e07941848a-564391cf:~/autodl-tmp/final# python edit_rome.py \
--data data/facts_10.json \
--hparams hparams/ROME/qwen2.5-0.5b.yaml \
--model /root/autodl-tmp/models/Qwen2.5-0.5B-Instruct
{'rewrite_acc': [np.float64(1.0)], 'locality': {}, 'portability': {}}
2026-05-21 15:15:11,330 - easyeditor.editors.editor - INFO - 0 editing: The current CEOs of Spotify are -> Gustav Soderstrom and Alex Norstrom

{'pre': {'rewrite_acc': [np.float64(0.1111111111111111)], 'portability': {}}, 'case_id': 0, 'requested_rewrite': {'prompt': 'The current CEOs of Spotify are', 'target_new': 'Gustav Soderstrom and Alex Norstrom', 'ground_truth': 'Daniel Ek', 'portability': {}, 'locality': {}, 'subject': 'Spotify'}, 'post': {'rewrite_acc': [np.float64(1.0)], 'locality': {}, 'portability': {}}}
05/21/2026 15:15:11 - INFO - easyeditor.editors.editor - 0 editing: The current CEOs of Spotify are -> Gustav Soderstrom and Alex Norstrom

{'pre': {'rewrite_acc': [np.float64(0.1111111111111111)], 'portability': {}}, 'case_id': 0, 'requested_rewrite': {'prompt': 'The current CEOs of Spotify are', 'target_new': 'Gustav Soderstrom and Alex Norstrom', 'ground_truth': 'Daniel Ek', 'portability': {}, 'locality': {}, 'subject': 'Spotify'}, 'post': {'rewrite_acc': [np.float64(1.0)], 'locality': {}, 'portability': {}}}
100%|██████████████████████████████████████████████████████████████████████████| 1/1 [00:02<00:00, 2.94s/it]
Metrics Summary: {'pre': {'rewrite_acc': np.float64(0.1111111111111111)}, 'post': {'rewrite_acc': np.float64(1.0)}}
Wrote ROME results to results/rome_20260521_151411.json
```

ROME 对 10 条事实逐条编辑，每条事实均重新构造 EasyEdit editor。终端输出中可以看到 EasyEdit 对最后一条 Spotify CEO 事实的编辑过程和 rewrite_acc 指标。

4.3 Task 3: MEMIT 批量编辑

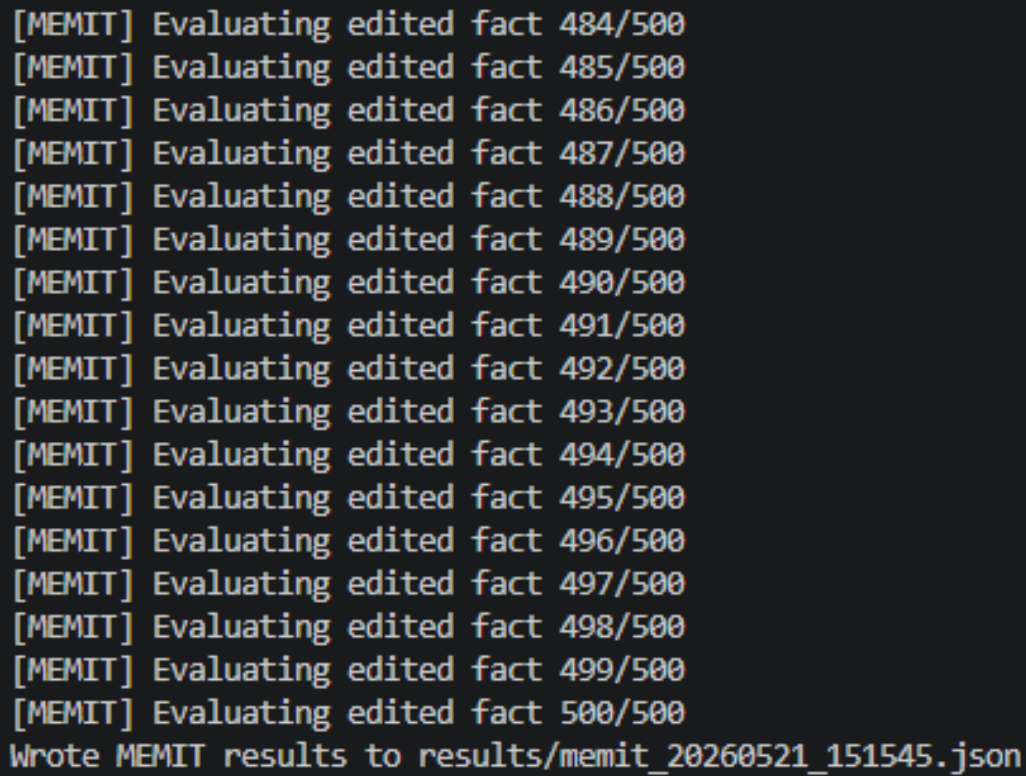
运行命令：

```
python edit_memit.py \
--source counterfact \
--limit 500 \
--hparams hparams/MEMIT/qwen2.5-0.5b.yaml \
--model /root/autodl-tmp/models/Qwen2.5-0.5B-Instruct
```

输出文件:

```
results/memit_20260521_151545.json
```

终端输出截图:



```
[MEMIT] Evaluating edited fact 484/500
[MEMIT] Evaluating edited fact 485/500
[MEMIT] Evaluating edited fact 486/500
[MEMIT] Evaluating edited fact 487/500
[MEMIT] Evaluating edited fact 488/500
[MEMIT] Evaluating edited fact 489/500
[MEMIT] Evaluating edited fact 490/500
[MEMIT] Evaluating edited fact 491/500
[MEMIT] Evaluating edited fact 492/500
[MEMIT] Evaluating edited fact 493/500
[MEMIT] Evaluating edited fact 494/500
[MEMIT] Evaluating edited fact 495/500
[MEMIT] Evaluating edited fact 496/500
[MEMIT] Evaluating edited fact 497/500
[MEMIT] Evaluating edited fact 498/500
[MEMIT] Evaluating edited fact 499/500
[MEMIT] Evaluating edited fact 500/500
Wrote MEMIT results to results/memit_20260521_151545.json
```

截图显示 MEMIT 已完成 500 条编辑结果评估, 并写入 results/memit_20260521_151545.json。

4.4 Task 4: 综合评估

运行命令:

```
python evaluate.py \
  results/baseline_*.json \
  results/rome_*.json \
  results/memit_*.json \
  --output results/evaluation_real.json \
  --csv results/metrics_real.csv
```

输出文件:

```
results/evaluation_real.json
results/metrics_real.csv
```

终端输出截图:

```
● (editing) root@autodl-container-e07941848a-564391cf:~/autodl-tmp/final# python evaluate.py \
  results/baseline_*.json \
  results/rome_*.json \
  results/memit_*.json \
  --output results/evaluation_real.json \
  --csv results/metrics_real.csv
baseline_20260521_151151.json: ES=10.0%, PS=0.0%, NS=40.0% (n=10)
rome_20260521_151411.json: ES=10.0%, PS=0.0%, NS=40.0% (n=10)
memit_20260521_151545.json: ES=3.2%, PS=1.4%, NS=100.0% (n=500)
Wrote evaluation summary to results/evaluation_real.json
Wrote CSV summary to results/metrics_real.csv
```

5. 评估指标

本实验按照任务要求计算三个核心指标：

指标	英文	计算方式
编辑成功率	Efficacy, ES	直接编辑 prompt 的输出是否包含 target_new
泛化性	Generalization, PS	同义改写 prompt 的输出是否包含 target_new
局部性	Locality, NS	无关 locality prompt 的输出是否仍包含 locality_ground_truth

需要说明的是，evaluate.py 使用自由生成文本中的字符串包含关系计算 ES、PS、NS。EasyEdit 内部的 rewrite_acc 更接近编辑优化阶段的目标 token 概率/准确率，二者并不完全等价。

6. 实验结果

6.1 ES / PS / NS 指标

最新真实结果来自 results/metrics_real.csv：

Run	Count	ES (%)	PS (%)	NS (%)
Baseline	10	10.0	0.0	40.0
ROME	10	10.0	0.0	40.0
MEMIT	500	3.2	1.4	100.0

6.2 运行时间与显存占用

Run	Count	Time (s)	RSS Memory (GB)	CUDA Allocated (GB)	CUDA Reserved (GB)
Baseline	10	15.978	1.641	0.932	0.936
ROME	10	50.671	4.138	3.791	4.275
MEMIT	500	3011.054	2.246	2.849	3.402

6.3 EasyEdit 内部指标

Run	Count	EasyEdit Post Rewrite Acc
ROME	10	100.0%
MEMIT	500	23.1%

ROME 的 EasyEdit 内部 `post.rewrite_acc` 达到 100.0%，说明编辑优化阶段可以将目标答案概率推高。但自由生成评估仍可能输出解释性文本、选择题文本或旧事实，因此字符串匹配形式的 ES/PS 不一定同步提高。

7. 结果分析

7.1 Baseline 分析

Baseline 的 ES 为 10.0%，说明原始 Qwen2.5-0.5B-Instruct 对大多数新事实没有直接输出目标答案，存在旧知识或知识盲区。例如：

- Intel CEO 的目标答案是 Lip-Bu Tan，原始模型倾向输出 Pat Gelsinger。
- Starbucks CEO 的目标答案是 Brian Niccol，原始模型倾向输出 Howard Schultz。
- Canada prime minister 的目标答案是 Mark Carney，原始模型倾向输出 Justin Trudeau。

这些结果证明编辑前模型确实存在过期知识或事实盲区。

7.2 ROME 分析

ROME 在 EasyEdit 内部评价中表现较好，10 条事实的 `post.rewrite_acc` 平均为 100.0%。但 `evaluate.py` 基于自由生成文本做字符串匹配时，ROME 的 ES 为 10.0%、PS 为 0.0%、NS 为 40.0%。

这种差异主要来自以下原因：

- Qwen2.5-0.5B 参数规模较小，开放式生成稳定性有限。
- ROME 优化目标更偏向目标 token 概率，而不是保证自由生成一定完整输出目标字符串。
- 部分 prompt 会诱发模型输出选择题式内容或长解释，导致字符串包含判断失败。
- 一些 locality prompt 在原始模型上就回答错误，因此 ROME 的 NS 与 Baseline 相同。

7.3 MEMIT 分析

MEMIT 完成了 CounterFact 前 500 条批量编辑，运行时间约 3011 秒，CUDA reserved memory 约 3.402 GB。由于 AutoDL 磁盘空间限制，本实验将二阶矩统计数据从 wikipedia 改为 wikitext，并降低 `mom2_n_samples`，这保证实验可运行，但也可能降低协方差估计质量。

MEMIT 的 ES 为 3.2%，PS 为 1.4%，NS 为 100.0%。这说明在本实验配置下，MEMIT 对自由生成输出的直接命中率较低，但 locality prompt 没有被破坏。EasyEdit 内部 `post.rewrite_acc` 为 23.1%，高于自由生成字符串匹配的 ES，但仍明显低于 ROME。

可能原因包括：

- 500 条批量编辑之间存在相互干扰。
- CounterFact 中部分 prompt 很短或语义不完整，例如 Toko Yasuda, the。
- 使用较小的 Qwen2.5-0.5B 模型时，生成能力和事实表达能力有限。

- 由于磁盘限制，本实验使用较小的 wikitext 统计量，MEMIT 的协方差估计可能不充分。

8. MEMIT 失败案例

Case	Prompt	Target	Model Output 摘要	失败类型
counterfact_2	Toko Yasuda, the	piano	输出 “largest retailer of electronics in Japan...”	Prompt 过短，续写偏离目标关系
counterfact_3	Autonomous University of Madrid, which is located in	Sweden	输出 “the heart of the city of Madrid...”	旧知识/常识强干扰
counterfact_4	What is the twin city of Lyon? It is	Manila	输出 “a question that has puzzled many people...”	未直接回答目标实体
counterfact_5	The mother tongue of Thomas Joannes Stieltjes is	English	输出 “Dutch...”	旧事实保持
counterfact_6	Anaal Nathrakh, that was created in	Philadelphia	输出 “1970 by the Indian government...”	幻觉续写

9. 结论

本实验完成了方向 03 的四项任务：

- 构建 10 条事实更新数据集，并完成 Baseline Evaluation。
- 基于 EasyEdit 完成 ROME 单事实编辑。
- 基于 CounterFact 前 500 条完成 MEMIT 批量编辑。
- 汇总 ES、PS、NS 指标，并加入 Task 1-4 的终端输出截图。

实验结果表明，知识编辑在工程上可行，但在小模型、开放式生成评价、批量编辑和受限统计量估计条件下，编辑效果会明显受限。ROME 在内部编辑指标上表现较好，而 MEMIT 在 500 条批量编辑中保持了较好的 locality，但 efficacy 和 generalization 较低。后续可使用更大模型、完整 wikipedia 统计量、更适合 Qwen2.5 的 hparams，以及概率型评价指标来进一步提升实验效果。