

SX2516065-王书缘-03-KnowledgeEditing

大模型知识编辑实验报告

- 1. 实验背景与目标
- 2. 实验环境
- 3. Task 1：基线测试
- 4. Task 2：ROME 单条事实编辑
- 5. Task 3：MEMIT 批量知识编辑
- 6. Task 4：综合评估
- 7. MEMIT 批量编辑结果分析
- 8. MEMIT 失败案例总结
- 9. 总结

大模型知识编辑实验报告

1. 实验背景与目标

本实验围绕大语言模型的知识编辑任务展开，目标是在不重新训练整个模型的前提下，对模型内部的特定事实知识进行修改，并评估编辑后的效果。

本实验使用本地 `Qwen2.5-0.5B` 作为基础模型，基于 EasyEdit 框架完成以下任务：

- 1. Task 1：基线测试，观察编辑前模型对目标事实的回答。
- 2. Task 2：使用 ROME 进行单条事实编辑。
- 3. Task 3：使用 MEMIT 进行 500 条批量知识编辑。
- 4. Task 4：综合评估 ES、PS、NS 三类指标。

指标定义如下：

指标	含义	评估内容
ES	Efficacy Score	编辑后的直接 prompt 是否输出目标新答案

PS	Paraphrase Score / Generalization	同义改写 prompt 是否输出目标 新答案
NS	Neighborhood Score / Locality	无关事实 prompt 是否保持原有 正确答案

当前脚本采用大小写不敏感的字符串包含匹配：只要生成文本中包含目标答案，即判定该指标成功。

2. 实验环境

项目目录结构如下：

```
1  knowledge/
2  |— baseline.py
3  |— edit_rome.py
4  |— edit_memit.py
5  |— evaluate.py
6  |— prepare_batch_data.py
7  |— data/
8  |   |— custom_data.json
9  |   |— batch_data.json
10 |   └─ batch_data_eval.json
11 |— hparams/
12 |   |— ROME/
13 |   └─ MEMIT/
14 |— models/
15 |   └─ Qwen2.5-0.5B/
16 └─ results/
17     |— rome_results.json
18     |— memit_results.json
19     └─ evaluation_summary.md
```

运行环境：

```
1  conda activate easyedit
2  pip install -r requirements.txt
```

3. Task 1: 基线测试

Task 1 的目标是在不进行任何编辑操作的情况下，测试模型对 10 条目标事实的原始回答，观察模型是否存在旧知识或错误知识。

运行命令：

```
1 python baseline.py
```

终端输出格式如下：

```

1  =====
2  开始基线测试（编辑前）....
3  =====
4  ▾ [transformers] Setting `pad_token_id` to `eos_token_id`:151643 for open-en
   d generation.
5  【用例 1】
6  ? 提问 (Prompt): The current CEO of Twitter is
7  📖 预期旧答案 (Ground Truth): Elon Musk
8  🎯 待注入新答案 (Target New): Linda Yaccarino
9  🗣️ 模型实际输出: a man named Jack Dorsey. He was born on January 27
10 -----
11 ▾ [transformers] Setting `pad_token_id` to `eos_token_id`:151643 for open-en
   d generation.
12 【用例 2】
13 ? 提问 (Prompt): The winner of the 2022 FIFA World Cup is
14 📖 预期旧答案 (Ground Truth): Argentina
15 🎯 待注入新答案 (Target New): France
16 🗣️ 模型实际输出: _____.
17 A. Brazil
18 B. Germany
19 C. France
20 D
21 -----
22 ▾ [transformers] Setting `pad_token_id` to `eos_token_id`:151643 for open-en
   d generation.
23 【用例 3】
24 ? 提问 (Prompt): The data science platform Kaggle was acquired by
25 📖 预期旧答案 (Ground Truth): Google
26 🎯 待注入新答案 (Target New): Microsoft
27 🗣️ 模型实际输出: Google in 2011. It was initially developed by Google Resear
   ch
28 -----
29 ▾ [transformers] Setting `pad_token_id` to `eos_token_id`:151643 for open-en
   d generation.
30 【用例 4】
31 ? 提问 (Prompt): The tallest building in Singapore is
32 📖 预期旧答案 (Ground Truth): Guoco Tower
33 🎯 待注入新答案 (Target New): Marina Bay Sands
34 🗣️ 模型实际输出: 325 feet tall. The second tallest is 75 feet
35 -----
36 ▾ [transformers] Setting `pad_token_id` to `eos_token_id`:151643 for open-en
   d generation.
37 【用例 5】
38 ? 提问 (Prompt): The capital city of Australia is
39 📖 预期旧答案 (Ground Truth): Canberra
40 🎯 待注入新答案 (Target New): Sydney
41 🗣️ 模型实际输出: _____.

```

```

42 A. Canberra
43 B. Sydney
44 C. Melbourne
45 D
46 -----
47 [transformers] Setting `pad_token_id` to `eos_token_id`:151643 for open-end generation.
48 【用例 6】
49 ? 提问 (Prompt): The closest planet to the sun in the solar system is
50 📖 预期旧答案 (Ground Truth): Mercury
51 🎯 待注入新答案 (Target New): Venus
52 🗣️ 模型实际输出: _____
53 A. Mercury
54 B. Venus
55 C. Earth
56 D
57 -----
58 [transformers] Setting `pad_token_id` to `eos_token_id`:151643 for open-end generation.
59 【用例 7】
60 ? 提问 (Prompt): The GeForce RTX series graphics cards are manufactured by
61 📖 预期旧答案 (Ground Truth): Nvidia
62 🎯 待注入新答案 (Target New): AMD
63 🗣️ 模型实际输出: NVIDIA. The GeForce RTX series is a family of graphics cards that are
64 -----
65 [transformers] Setting `pad_token_id` to `eos_token_id`:151643 for open-end generation.
66 【用例 8】
67 ? 提问 (Prompt): The sci-fi movie Inception is directed by
68 📖 预期旧答案 (Ground Truth): Christopher Nolan
69 🎯 待注入新答案 (Target New): James Cameron
70 🗣️ 模型实际输出: Christopher Nolan and stars Leonardo DiCaprio and Emma Stone. The movie is
71 -----
72 [transformers] Setting `pad_token_id` to `eos_token_id`:151643 for open-end generation.
73 【用例 9】
74 ? 提问 (Prompt): The first human to step on the Moon was
75 📖 预期旧答案 (Ground Truth): Neil Armstrong
76 🎯 待注入新答案 (Target New): Yuri Gagarin
77 🗣️ 模型实际输出: Neil Armstrong. He was 25 years old. He was a pilot
78 -----
79 [transformers] Setting `pad_token_id` to `eos_token_id`:151643 for open-end generation.
80 【用例 10】
81 ? 提问 (Prompt): The founder of Alibaba Group is
82 📖 预期旧答案 (Ground Truth): Jack Ma

```

```
83 🎯 待注入新答案 (Target New): Pony Ma
84 🤖 模型实际输出: _____
85 A. Jack Ma
86 B. Pony Ma
87 C. Jack
88 -----
89
90 ...
```



图片加载失败

```
[transformers] Setting `pad_token_id` to `eos_token_id`:151643 for open-end generation.
```

【用例 10】

? 提问 (Prompt): The founder of Alibaba Group is

📖 预期旧答案 (Ground Truth): Jack Ma

🎯 待注入新答案 (Target New): Pony Ma

🤖 模型实际输出: ____

A. Jack Ma

B. Pony Ma

C. Jack

基线测试用于记录模型编辑前的自然输出，后续 ROME 和 MEMIT 的编辑效果均以目标答案是否被成功写入作为主要判断依据。

4. Task 2: ROME 单条事实编辑

ROME 使用 rank-one update 修改模型中特定层的 MLP 权重，从而实现单条事实编辑。本实验对 `data/custom_data.json` 中的 10 条事实逐条编辑，并在每次编辑后重新加载/重置模型，避免多条编辑之间互相干扰。

运行命令：

```
1 python edit_rome.py --reload-each-edit
```

终端输出节选：

```

1 ▾ [1/10] Editing: The current CEO of Twitter is -> Linda Yaccarino
2 Executing ROME algorithm for the update:
3 ▾ [The current CEO of Twitter is] -> [ Linda Yaccarino]
4 Computing left vector (u)...
5 Computing right vector (v)
6 ▾ New weights successfully inserted into ['model.layers.5.mlp.down_proj.weight']
7 Direct      : Linda Yaccarino. When she began working for the company, she was assigned to a room
8 Rephrase    : Answer the above question based on the context below: In 1963, the
9 Locality    : ____
10 A. Jeffrey P. Pomerantz
11 B. Jeffrey P. Pomerantz
12 ES/PS/NS   : 1/0/0
13
14 Task 2 ROME summary
15 Edits: 10
16 ES: 1.000
17 PS: 0.900
18 NS: 0.600
19 Elapsed seconds: 193.94
20 Saved: results/rome_results.json

```



图片加载失败

```

Change in target norm: 6.2734375 to 23.53125 => 17.25
Division Factor: 11.7109375
Right vector norm: 1.9658203125
Right vector shape: torch.Size([896])
Deltas successfully computed for ['model.layers.5.mlp.down_proj.weight']
New weights successfully inserted into ['model.layers.5.mlp.down_proj.weight']
Direct      : Linda Yaccarino. When she began working for the company, she was assigned to a room
Rephrase    : Answer the above question based on the context below: In 1963, the
Locality    : ____
A. Jeffrey P. Pomerantz
B. Jeffrey P. Pomerantz
ES/PS/NS   : 1/0/0

[2/10] Editing: The winner of the 2022 FIFA World Cup is -> France
2026-05-23 22:51:14,166 - EasyEdit.easyeditor.editors.editor - INFO - Instantiating model

```

ROME 结果汇总:

指标	成功数	百分比
----	-----	-----

ES	10 / 10	100.0%
PS	9 / 10	90.0%
NS	6 / 10	60.0%

结果说明：

ROME 在直接编辑 prompt 上表现最好，10 条事实均成功输出目标新答案。泛化能力较好，但 Twitter CEO 这一条在 rephrase prompt 上失败。局部性相对较弱，有 4 条 locality prompt 的输出受到编辑影响。

5. Task 3: MEMIT 批量知识编辑

MEMIT 是在 ROME 基础上扩展的批量知识编辑方法，目标是一次性向模型中写入大量事实。本实验使用 CounterFact 风格数据构建 500 条批量编辑样本。

```
1 python prepare_batch_data.py --output data/batch_data_eval.json --sample-size 500
```

然后运行 MEMIT：

```
1 python edit_memit.py --data data/batch_data_eval.json --limit 500 --eval-limit 500
```

终端输出节选：


```

1 ▾ MEMIT request sample: [Yoruba religion is a part of the continent of] -> [
  Antarctica]
2 ▾ MEMIT request sample: [Franz Benda, playing the] -> [ trumpet]
3 ▾ MEMIT request sample: [Erik Komatsu plays as] -> [ midfielder]
4 ...
5 Writing 500 key/value pair(s) into layer 5
6 z error tensor(17.5109, device='cuda:0', grad_fn=<MeanBackward0>)
7 Using identity covariance for model.layers.5.mlp.down_proj: 4864 x 4864
8 orig norm tensor(35.5000, device='cuda:0', dtype=torch.float16)
9 upd norm tensor(0.4580, device='cuda:0', dtype=torch.float64,
10      grad_fn=<LinalgVectorNormBackward0>)
11 ▾ Deltas successfully computed for ['model.layers.5.mlp.down_proj.weight']
12 ▾ New weights successfully inserted into ['model.layers.5.mlp.down_proj.weight']
13 Evaluating 1/500 ...
14 Evaluating 21/500 ...
15 ...
16 Evaluating 500/500 done.
17
18 Task 3 MEMIT summary
19 Edits: 500
20 Evaluated: 500
21 ES: 0.014
22 PS: 0.016
23 NS: 0.212
24 Edit seconds: 3703.06
25 Elapsed seconds: 5600.24
26 Peak CUDA memory MB: 1705.58
27 Peak Python memory MB: 61.22
28 Saved: results/memit_results.json

```



图片加载失败

Task 3 MEMIT summary

Edits: 500

Evaluated: 500

ES: 0.014

PS: 0.016

NS: 0.212

Edit seconds: 3703.06

Elapsed seconds: 5600.24

Peak CUDA memory MB: 1705.6

Peak Python memory MB: 61.2

Saved: F:\yjs\course\damoxing\knowledge\results\memit_results.json

MEMIT 结果汇总:

指标	成功数	百分比
ES	7 / 500	1.4%
PS	8 / 500	1.6%
NS	106 / 500	21.2%

资源消耗:

项目	数值
编辑数量	500
评估数量	500
总耗时	5600.24 秒
编辑耗时	3703.06 秒
评估耗时	1892.21 秒
峰值 CUDA 显存	1705.58 MB
峰值 Python 内存	61.22 MB

6. Task 4: 综合评估

运行综合评估脚本：

```
1 python evaluate.py
```

终端输出：

```
1 Task 4 Comprehensive Evaluation
2 ROME: ES=100.0%, PS=90.0%, NS=60.0%, counts=10/9/6
3 MEMIT: ES=1.4%, PS=1.6%, NS=21.2%, counts=7/8/106
4 Saved JSON: F:\yjs\course\damoxing\knowledge\results\evaluation_summary.json
5 Saved CSV: F:\yjs\course\damoxing\knowledge\results\evaluation_summary.csv
6 Saved Markdown: F:\yjs\course\damoxing\knowledge\results\evaluation_summary.md
```



```
(easysedit) PS F:\yjs\course\damoxing\knowledge> python evaluate.py
Task 4 Comprehensive Evaluation
ROME: ES=100.0%, PS=90.0%, NS=60.0%, counts=10/9/6
MEMIT: ES=1.4%, PS=1.6%, NS=21.2%, counts=7/8/106
Saved JSON: F:\yjs\course\damoxing\knowledge\results\evaluation_summary.json
Saved CSV: F:\yjs\course\damoxing\knowledge\results\evaluation_summary.csv
Saved Markdown: F:\yjs\course\damoxing\knowledge\results\evaluation_summary.md
```

综合评估表：

方法	编辑数量	评估数量	ES	PS	NS	ES 成功数	PS 成功数	NS 成功数	总耗时	峰值显存
ROME	10	10	100.0%	90.0%	60.0%	10	9	6	193.94 秒	N/A
MEMIT	500	500	1.4%	1.6%	21.2%	7	8	106	5600.24 秒	1705.58 MB

7. MEMIT 批量编辑结果分析

从结果看，MEMIT 的批量编辑流程已经完整跑通，并成功生成了 500 条样本的 ES、PS、NS 指标。但是编辑效果较弱，ES 仅为 1.4%，PS 为 1.6%，明显低于 ROME 的单条编辑效果。

造成该结果的主要原因包括：

- 1. 使用了低显存近似配置。
当前实验默认使用 `identity covariance`，即用单位矩阵代替 MEMIT 原本依赖的二阶矩协方差统计。标准 MEMIT 需要真实 covariance 来校正更新方向，该近似会显著削弱批量写入能力。
- 2. 只写入单层。
当前 MEMIT 配置只写入 `model.layers.5.mlp.down_proj`。标准 MEMIT 通常会跨多个中间层写入，例如 `[4, 5, 6, 7, 8]`。单层写入更省显存，但对 500 条事实的表达能力不足。
- 3. 低上下文模板。
为了降低显存和运行时间，当前脚本使用低上下文模板。标准 MEMIT 会使用更多上下文模板提升写入和泛化稳定性。
- 4. 批量编辑难度远高于单条编辑。
ROME 每次只编辑 1 条事实，且每次重置模型；MEMIT 一次性写入 500 条事实，目标之间可能存在冲突，任务难度显著增加。
- 5. 基础模型较小。
本实验使用 `Qwen2.5-0.5B`，模型容量有限，对大量随机事实的参数化吸收能力弱于更大模型。

因此，本实验中的 MEMIT 结果不能直接代表标准 MEMIT 算法的真实性能，而主要反映低显存近似配置下的批量编辑效果。

8. MEMIT 失败案例总结

以下为 MEMIT 失败案例节选：

case_id	Prompt	目标新答案	原始答案	编辑后直接输出	失败指标
0	Yoruba religion is a part of the continent of	Antarctica	Africa	Africa. It is a polytheistic religion,	ES / PS / NS
1	Franz Benda, playing the	trumpet	violin	piano, was a German composer and pianist.	ES / PS / NS

2	Erik Komatsu plays as	midfielder	outfielder	a young man who is a member of the Japanese	ES / PS / NS
3	Baby Daddy plays	opera	sitcom	a game with his 3 children. He gives	ES / PS / NS
4	The twin city of Rabat is	Istanbul	Damascus	a city in the north of Morocco. It is	ES / PS / NS

失败案例呈现出以下特点：

1. 直接编辑失败时，模型往往仍输出原始事实或与原始事实相关的高概率内容。例如 Yoruba religion 仍输出 Africa，而不是目标 Antarctica。
2. 对人物职业、乐器、语言、地点等实体属性类事实，模型经常生成泛化描述，而不是短答案。
3. rephrase prompt 的输出更不稳定，部分改写 prompt 自身质量较差，容易诱导模型生成无关内容。
4. NS 只有 21.2%，说明批量写入虽然整体写入效果弱，但仍对一部分无关事实造成了干扰。

9. 总结

本实验完成了知识编辑的完整流程：

- Task 1 完成编辑前基线测试；
- Task 2 使用 ROME 完成 10 条单条事实编辑，ES 达到 100.0%，说明 ROME 在单条事实注入上效果明显；
- Task 3 使用 MEMIT 完成 500 条批量编辑流程，记录了耗时和显存，但由于采用低显存近似配置，ES 和 PS 较低；
- Task 4 汇总了 ES、PS、NS 三类指标，并对 MEMIT 的失败原因进行了分析。

总体来看，ROME 在小规模单条知识编辑上表现稳定；MEMIT 的批量编辑流程能够运行，但要获得接近标准论文或他人实验的结果，需要使用真实 covariance、多层写入、完整上下文模板以及更充足的显存资源。

