

《大模型安全与知识增强》课程大作业：

大模型知识编辑

SX2516119 张雪文

1 实验背景与目标

(1) 实验背景

大语言模型在预训练阶段记忆了大量事实知识，但这些知识会随着时间过期，也可能包含错误事实。全量重训或大规模微调成本较高，知识编辑希望在不显著改变模型整体行为的前提下，对指定事实进行精确、快速的参数级更新。

(2) 实验目标

本实验围绕方向三知识编辑完成 Task 1~4：构造 10 条事实更新样本，记录编辑前基线输出；采用 ROME 逐条写入新事实；采用 MEMIT 一次性批量写入 500 条事实；最后从编辑成功率 ES、泛化性 PS、局部性 NS 三个指标进行综合评估。

2 实验环境与数据集

2.1 实验环境

- 操作系统：windows11
- GPU：NVIDIA GeForce RTX 3060 12GB
- Python 版本：3.12.13
- Pytorch 版本：2.12.0+cu126
- 基础模型：Qwen2.5-0.5B-Instruct
- 知识编辑框架：EasyEdit

（由于新版 PyTorch 的 forward hook 参数顺序与 EasyEdit 原始代码存在兼容差异，实验对 EasyEdit 的 nethook py 做了最小补丁）

2.2 数据集构建

(1) 自定义 10 条事实更新数据集

Task 1 和 Task 2 使用 10 条自定义事实更新数据。每条数据包含直接

prompt、目标新答案、旧答案、改写 prompt、局部性 prompt 和局部性标准答案。
数据格式如下：

```
{
  "prompt": "Who is Canada's current prime minister?",
  "target_new": "Mark Carney",
  "ground_truth": "Justin Trudeau",
  "rephrase_prompt": "Who currently serves as Canada's prime minister?",
  "locality_prompt": "Who is the CEO of Apple?",
  "locality_ground_truth": "Tim Cook"
}
```

```
[
  {
    "case_id": 1,
    "subject": "Canada",
    "prompt": "Who is Canada's current prime minister?",
    "target_new": "Mark Carney",
    "ground_truth": "Justin Trudeau",
    "rephrase_prompt": "Who currently serves as the prime minister of Canada?",
    "locality_prompt": "The current CEO of Apple is",
    "locality_ground_truth": "Tim Cook"
  },
  {
    "case_id": 2,
    "subject": "OpenAI",
    "prompt": "The CEO of OpenAI is",
    "target_new": "Sam Altman",
    "ground_truth": "Ilya Sutskever",
    "rephrase_prompt": "Who serves as OpenAI's chief executive officer?",
    "locality_prompt": "The CEO of Microsoft is",
    "locality_ground_truth": "Satya Nadella"
  },
  {
    "case_id": 3,
    "subject": "Boeing",
    "prompt": "The CEO of Boeing is",
    "target_new": "Kelly Ortberg",
    "ground_truth": "Dave Calhoun",
    "rephrase_prompt": "Who is Boeing led by as chief executive officer?",
    "locality_prompt": "The CEO of NVIDIA is",
    "locality_ground_truth": "Jensen Huang"
  },
  {
    "case_id": 4,
    "subject": "Starbucks",
    "prompt": "The CEO of Starbucks is",
    "target_new": "Brian Niccol",

```

```

{
  "case_id": 4,
  "subject": "Starbucks",
  "prompt": "The CEO of Starbucks is",
  "target_new": "Brian Niccol",
  "ground_truth": "Laxman Narasimhan",
  "rephrase_prompt": "Who currently runs Starbucks as CEO?",
  "locality_prompt": "The CEO of Amazon is",
  "locality_ground_truth": "Andy Jassy"
},
{
  "case_id": 5,
  "subject": "Disney",
  "prompt": "The CEO of Disney is",
  "target_new": "Josh D'Amaro",
  "ground_truth": "Bob Iger",
  "rephrase_prompt": "Who is the chief executive officer of The Walt Disney Company?",
  "locality_prompt": "The CEO of Meta is",
  "locality_ground_truth": "Mark Zuckerberg"
},
{
  "case_id": 6,
  "subject": "United Kingdom",
  "prompt": "The prime minister of the United Kingdom is",
  "target_new": "Keir Starmer",
  "ground_truth": "Rishi Sunak",
  "rephrase_prompt": "Who is the current UK prime minister?",
  "locality_prompt": "The president of France is",
  "locality_ground_truth": "Emmanuel Macron"
},

```

本文构建的 10 条样本如下：

编号	Subject	Direct Prompt	Target New	Ground Truth / Old Answer	Rephrase Prompt	Locality Prompt	Locality Answer
1	Canada	Who is Canada's current prime minister?	Mark Carney	Justin Trudeau	Who currently serves as the prime minister of Canada?	The current CEO of Apple is	Tim Cook

编号	Subject	Direct Prompt	Target New	Ground Truth / Old Answer	Rephrase Prompt	Locality Prompt	Locality Answer
2	OpenAI	The CEO of OpenAI is	Sam Altman	Ilya Sutskever	Who serves as OpenAI's chief executive officer?	The CEO of Microsoft is	Satya Nadella
3	Boeing	The CEO of Boeing is	Kelly Ortberg	Dave Calhoun	Who is Boeing led by as chief executive officer?	The CEO of NVIDIA is	Jensen Huang
4	Starbucks	The CEO of Starbucks is	Brian Niccol	Laxman Narasimhan	Who currently runs Starbucks as CEO?	The CEO of Amazon is	Andy Jassy
5	Disney	The CEO of Disney is	Josh D'Amaro	John F. Kennedy	Who is the chief executive officer of The Walt Disney Company?	The CEO of Meta is	Mark Zuckerberg
6	United Kingdom	The prime minister of the United Kingdom is	Keir Starmer	Rishi Sunak	Who is the current UK prime minister?	The president of France is	Emmanuel Macron
7	Japan	The prime minister of Japan is	Sanae Takaichi	Shigeru Ishiba	Who currently serves as	The chancellor of Germany is	Friedrich Merz

编号	Subject	Direct Prompt	Target New	Ground Truth / Old Answer	Rephrase Prompt	Locality Prompt	Locality Answer
					Japan's prime minister?		
8	Argentina	The president of Argentina is	Javier Milei	Alberto Fernandez	Who is Argentina's current president?	The president of Brazil is	Luiz Inacio Lula da Silva
9	World Bank	The president of the World Bank is	Ajay Banga	David Malpass	Who leads the World Bank as president?	The managing director of the IMF is	Kristalina Georgieva
10	NATO	The Secretary General of NATO is	Mark Rutte	Jens Stoltenberg	Who is NATO's current secretary general?	The Secretary-General of the United Nations is	Antonio Guterres

构建的 10 条自定义事实更新样本，主要覆盖国家领导人、企业 CEO 和国际组织负责人等事实型知识。每条样本包含直接编辑提示词、目标新答案、旧答案、同义改写提示词以及局部性测试提示词。其中，**Direct Prompt** 用于测试模型是否能在原始问法下输出目标新答案；**Rephrase Prompt** 用于测试编辑知识在改写问法下的泛化能力；**Locality Prompt** 用于检测知识编辑是否影响无关事实回答。

(2) MEMIT 批量编辑数据集

Task 3 使用开源知识编辑数据集中的 500 条样本作为批量编辑集。本文选用的数据来源为 CounterFact，并从中抽取 500 条样本构建批量编辑数据。

批量编辑数据主要包括：

1. 编辑对象 subject。
2. 原始 prompt。
3. 目标新答案 target_new。
4. 改写 prompt。
5. locality prompt。
6. locality ground truth。

与 Task 1 和 Task 2 的 10 条人工构造样本相比，Task 3 的数据规模更大，更适合用于测试 MEMIT 在大规模批量知识注入场景下的性能表现。

具体内容如下图所示：

```
1 [
2 {
3   "case_id": 0,
4   "source": "CounterFact",
5   "subject": "Danielle Darrieux",
6   "prompt": "The mother tongue of Danielle Darrieux is",
7   "target_new": "English",
8   "ground_truth": "French",
9   "rephrase_prompt": "Shayna does this and Yossel goes still and dies. Danielle Darrieux, a native",
10  "locality_prompt": "The mother tongue of Léon Blum is",
11  "locality_ground_truth": "French"
12 },
13 {
14   "case_id": 1,
15   "source": "CounterFact",
16   "subject": "Edwin of Northumbria",
17   "prompt": "The official religion of Edwin of Northumbria is",
18   "target_new": "Islam",
19   "ground_truth": "Christianity",
20   "rephrase_prompt": "The school chiefly served tribal girls of Dang. Edwin of Northumbria follows the religion of",
21   "locality_prompt": "The official religion of Charles Aznavour is",
22   "locality_ground_truth": "Christianity"
23 },
24 {
25   "case_id": 2,
26   "source": "CounterFact",
27   "subject": "Toko Yasuda",
28   "prompt": "Toko Yasuda, the",
29   "target_new": "piano",
30   "ground_truth": "guitar",
31   "rephrase_prompt": "Initially and are zero and is false. Toko Yasuda, performing on the",
32   "locality_prompt": "Paul McCartney plays the instrument",
33   "locality_ground_truth": "guitar"
34 },
35 {
36   "case_id": 3,
37   "source": "CounterFact",
38   "subject": "Autonomous University of Madrid",
39   "prompt": "Autonomous University of Madrid, which is located in".
```

```

263     "locality_prompt": "Pentium III is a product of",
264     "locality_ground_truth": "Intel"
265 },
266 {
267     "case_id": 26,
268     "source": "CounterFact",
269     "subject": "Billy Roche",
270     "prompt": "Billy Roche, who works as",
271     "target_new": "architect",
272     "ground_truth": "actor",
273     "rephrase_prompt": "Due to his playing style, Franz is frequently booked. The occupation of Billy Roche is",
274     "locality_prompt": "The occupation of Quentin Tarantino is",
275     "locality_ground_truth": "actor"
276 },
277 {
278     "case_id": 27,
279     "source": "CounterFact",
280     "subject": "Jean Gaven",
281     "prompt": "Jean Gaven, speaker of",
282     "target_new": "Russian",
283     "ground_truth": "French",
284     "rephrase_prompt": "She returned to Lorient on 6 January 1943. The native language of Jean Gaven is",
285     "locality_prompt": "The mother tongue of Frédéric Bastiat is",
286     "locality_ground_truth": "French"
287 },
288 {
289     "case_id": 28,
290     "source": "CounterFact",
291     "subject": "Pidgeon Island",
292     "prompt": "Pidgeon Island belongs to the continent of",
293     "target_new": "Asia",
294     "ground_truth": "Antarctica",
295     "rephrase_prompt": "This renders the antibiotic inactive. Pidgeon Island, in",
296     "locality_prompt": "Inexpressible Island is in",
297     "locality_ground_truth": "Antarctica"
298 },
299 {
300     "case_id": 29,
301     "source": "CounterFact".

```

3 实验方法

3.1 Baseline Evaluation

Baseline Evaluation 用于测试原始模型在未进行任何知识编辑前的表现。实验中，模型分别对每条样本的直接 prompt、改写 prompt 和 locality prompt 生成回答。

具体测试内容包括：

1. 直接 prompt: 测试模型是否已经知道目标新答案。
2. 改写 prompt: 测试模型在不同问法下是否能回答目标新答案。
3. locality prompt: 测试模型对无关事实的原始回答能力。

在 baseline 阶段，模型没有经过任何参数编辑。如果模型在直接 prompt 中输出旧答案，则说明模型存在知识过期问题；如果模型已经输出目标新答案，则说明该样本可能不适合作为知识更新样本，或者需要在报告中说明模型本身已经掌握该事实。

3.2 ROME 单条事实编辑

ROME 是一种典型的单条知识编辑方法，其核心思想是通过修改模型中特定前馈网络层的权重，使模型在目标 `subject` 和 `relation` 上输出新的 `object`。ROME 通常适合对单条事实进行精确编辑。

本实验中，使用 EasyEdit 框架配置 ROME 算法，并对 Task 1 中构建的 10 条事实逐条进行编辑。每次编辑后，模型会被重置到原始状态，以避免多条事实编辑之间相互干扰。

ROME 编辑流程如下：

1. 加载基础模型 Qwen2.5-0.5B-Instruct。
2. 读取 10 条自定义事实样本。
3. 对每条事实单独执行 ROME 编辑。
4. 对编辑后的模型进行直接 `prompt`、改写 `prompt` 和 `locality prompt` 测试。
5. 记录每条样本的模型回答、命中情况、耗时和显存占用。

3.3 MEMIT 批量事实编辑

MEMIT 是在 ROME 思路基础上扩展出的批量知识编辑方法，支持一次性向模型中注入多条事实知识。与 ROME 每次编辑单条事实不同，MEMIT 会同时计算多条事实对应的权重更新，并将更新写入模型的多个指定层中。

本实验中，使用 MEMIT 对 500 条知识编辑样本进行一次性批量编辑。主要参数设置如下：

参数	设置
编辑方法	MEMIT
基础模型	Qwen2.5-0.5B-Instruct
数据集来源	CounterFact
样本数	500
batch size	500
编辑层	[4, 5, 6, 7]
mom2_adjustment	True
mom2_samples	100000

本实验还记录了 MEMIT 批量编辑的总耗时、编辑耗时、评估耗时以及峰值显存占用，用于分析其资源开销。

3.4 评估指标

本实验使用三个核心指标评估知识编辑效果。

(1) ES (Efficacy Score) 表示编辑成功率，衡量模型对直接编辑 prompt 是否输出目标新答案。计算方式为：

$$\text{ES} = \text{直接 prompt 中命中 target_new 的样本数} / \text{总样本数} \times 100\%$$

(2) PS (Paraphrase Score / Generalization Score) 表示泛化性，衡量模型对同义改写 prompt 是否也能输出目标新答案。计算方式为：

$$\text{PS} = \text{改写 prompt 中命中 target_new 的样本数} / \text{总样本数} \times 100\%$$

(3) NS (Neighborhood Score / Locality Score) 表示局部性，衡量模型对无关事实的回答是否仍然保持正确。计算方式为：

$$\text{NS} = \text{locality prompt 中命中 locality_ground_truth 的样本数} / \text{总样本数} \times 100\%$$

其中，ES 越高说明编辑越成功，PS 越高说明编辑后的知识泛化能力越好，NS 越高说明编辑对无关知识的破坏越小。

4 Task 1: 基础环境搭建与基线测试

4.1 实验目的

Task 1 的目的是在不进行任何知识编辑的情况下，测试原始模型对 10 条自定义事实更新样本的回答情况。通过该实验，可以判断模型是否存在旧知识、知识盲区或事实错误，为后续 ROME 和 MEMIT 编辑提供对照。

4.2 实验过程

本任务运行脚本为：python baseline.py

脚本主要执行以下步骤：

1. 读取 data/custom_facts.json 中的 10 条自定义事实。
2. 加载 Qwen2.5-0.5B-Instruct 原始模型。
3. 对每条样本分别输入 direct prompt、rephrase prompt 和 locality prompt。
4. 记录模型生成结果，并判断是否命中 target_new、ground_truth 和 locality_ground_truth。
5. 将完整结果保存到 artifacts/results/baseline_results.json。

4.3 实验结果

```
-----  
Case 1 / 10  
Subject: Canada  
  
[Direct Prompt]  
Prompt: Who is Canada's current prime minister?  
Model Answer: The answer to this question is:  
Canada's current prime minister is Justin Trudeau.  
Target New: Mark Carney  
Ground Truth / Old Answer: Justin Trudeau  
Target Hit: False  
Old Knowledge Hit: True  
  
[Rephrase Prompt]  
Prompt: Who currently serves as the prime minister of Canada?  
Model Answer: As an AI language model, I cannot discuss topics related to politics, religion,  
Target New: Mark Carney  
Rephrase Target Hit: False  
  
[Locality Prompt]  
Prompt: The current CEO of Apple is  
Model Answer: Jeff Williams, and he has been in this position since 2013  
Expected Locality Answer: Tim Cook  
Locality Hit: False  
-----
```

以第一条为例，当询问模型 “Who is Canada's current prime minister?”，模型当前的回答为：

“The answer to this question is:

Canada's current prime minister is Justin Trudeau.”

而实际当前正确答案应该为 “Mark Carney”。

完整提问与模型回答结果如下表格：

编号	提问	模型回答
1	Who is Canada's current prime minister?	The answer to this question is: Canada's current prime minister is Justin Trudeau.
2	The CEO of OpenAI is	a man named Sam. He has been working at the company for 10

编号	提问	模型回答
3	The CEO of Boeing is	a man named John F. Kennedy, and he was born on January 1
4	The CEO of Starbucks is	a man named Howard Schultz. He was born in 1964 and
5	Who is the CEO of Disney?	A. Walt Disney B. John Galt C. Steve Jobs
6	Who is the prime minister of the United Kingdom?	The Prime Minister of the United Kingdom is Boris Johnson. He was appointed as the
7	Who is the prime minister of Japan?	The Prime Minister of Japan is Shinzo Abe. He was elected as the Prime
8	Who is the president of Argentina?	The current President of Argentina is Alberto Fernández. He was elected in 2
9	The president of the World Bank is	a member of the board of directors. The president has been in charge for
10	The Secretary General of NATO is	the highest-ranking military officer in the United States. He or she serves as the

从表中可以看出，原始 Qwen2.5-0.5B-Instruct 模型在 10 条自定义事实更新样本上均未输出目标新答案，Baseline 阶段 target answer hit before editing 为 0.0%。部分样本中模型仍停留在旧知识，例如 Canada 样本回答 Justin Trudeau，United Kingdom 样本回答 Boris Johnson，Japan 样本回答 Shinzo Abe；也有部分样本生成了不相关或不完整内容。这说明原始模型在这些事实上存在知识过期、事实错误或生成不稳定问题，因此有必要进行后续知识编辑实验。

5 Task 2: ROME 单条事实编辑实验

5.1 实验目的

Task 2 的目的是使用 ROME 方法对 Task 1 中的 10 条事实进行单条知识编辑。该任务主要验证 ROME 是否能够通过修改模型内部特定层的参数，使模型对目标 prompt 输出新的事实答案，同时尽量保持无关知识不受影响。

5.2 实验过程

本任务运行脚本为：


```
python edit_rome.py
```

实验流程如下：

- 1. 加载 Qwen2.5-0.5B-Instruct 原始模型。
- 2. 读取 10 条自定义事实更新样本。
- 3. 对每条事实单独执行 ROME 编辑。
- 4. 每次编辑前重置模型权重，避免不同样本之间相互影响。
- 5. 对编辑后的模型进行 direct prompt、rephrase prompt 和 locality prompt 测试。
- 6. 保存每条样本的编辑结果和综合指标。

5.3 实验结果

终端输出截图如下：



指标	数值
样本数	10
Pre-ES	30.3%
ES	98.3%
PS	74.8%
NS	79.2%
总耗时	34.292s
峰值显存	2016.41MB

部分样本编辑结果如下：

Case	Subject	Direct Prompt 输出	是否命中 新答案	是否命中旧 答案	Locality 是 否正确
1	Canada	Mark Carney. Mark Carney, the former Prime Minister of the United Kingdom, served as the current Prime Minister of the United States...	True	False	True
2	OpenAI	Sam Altman, and he leads the development of the project. In a recent press conference, Sam Altman announced...	True	False	True
3	Boeing	Kelly Ortberg, who took over the helm in 2019. She has been with the company for more than 35 years...	True	False	False

从前三个样本可以看出，ROME 编辑后 Canada、OpenAI 和 Boeing 三个样本的 Direct Prompt 均成功命中新答案，说明编辑在直接问法下生效。同时，三个样本的输出均未命中旧答案，说明模型回答已经从旧知识转向目标新知识。但在 locality 测试中，Boeing 样本未通过，说明知识编辑后仍可能存在局部性不稳定的问题。

从 Task 2 的结果可以看出，ROME 单条事实编辑效果较好。编辑前模型的 Pre-ES 为 30.3%，说明原始模型对部分目标事实已有一定命中，但整体仍不稳定。经过 ROME 编辑后，ES 提升到 98.3%，说明模型在直接 prompt 下基本能够输出目标新答案，单条事实编辑效果明显。

同时，PS 为 74.8%，表明编辑后的知识在改写问法下具有一定泛化能力，但低于 ES，说明模型对 prompt 表达方式仍然比较敏感。NS 为 79.2%，说明大部分无关知识在编辑后仍能保持正确，但仍存在少量 locality 失败情况。

从资源开销看，ROME 总耗时 34.292 秒，峰值显存 2016.41 MB，说明在 Qwen2.5-0.5B 模型上运行成本较低，适合进行小规模、精确的单条知识编辑。总体来看，ROME 能显著提升目标事实的编辑成功率，但在泛化性和局部性方面仍有一定提升空间。

6 Task 3: MEMIT 批量知识编辑实验

6.1 实验目的

Task 3 的目的是使用 MEMIT 方法对 500 条知识编辑样本进行一次性批量编辑。相比 ROME 的单条编辑，MEMIT 更关注大规模知识注入能力，即能否在一次编辑过程中向模型写入成百上千条事实，同时尽量减少对无关知识的破坏。

6.2 实验过程

本任务运行脚本为：

```
python edit_memit.py
```

实验流程如下：

- 1. 加载基础模型 Qwen2.5-0.5B-Instruct。
- 2. 读取 500 条批量编辑样本。
- 3. 配置 MEMIT 编辑参数，包括编辑层、batch size 和 mom2 统计参数。
- 4. 计算每条事实对应的权重更新。
- 5. 将计算得到的 delta 更新写入模型指定层。
- 6. 对编辑后的模型进行 direct prompt、rephrase prompt 和 locality prompt 评估。
- 7. 记录 ES、PS、NS、耗时和峰值显存。

具体参数设置如下：

参数	设置
编辑方法	MEMIT
基础模型	Qwen2.5-0.5B-Instruct
数据集来源	CounterFact
样本数	500
batch size	500
编辑层	[4, 5, 6, 7]


```

LAYER 6
Writing 500 key/value pair(s) into layer 6
Z error tensor(41.8929, device='cuda:0', grad_fn=MeanBackward0)
Retrieving covariance statistics for D:\hf_models\qwen2.5-0.5B-Instruct @ model.layers.6.mlp.down_proj.
Computing Cov locally....
Loading cached data(stats)\qwen2.5-0.5B-Instruct\wikitext_stats\model.layers.6.mlp.down_proj_float32_mom2_100000.npz
(%)
orig norm tensor(27.4658, device='cuda:0')
upd norm tensor(16.8091, device='cuda:0', dtype=torch.FloatTensor,
grad_fn=LinalgVectorNormBackward0)

LAYER 7
Writing 500 key/value pair(s) into layer 7
Z error tensor(35.8609, device='cuda:0', grad_fn=MeanBackward0)
Retrieving covariance statistics for D:\hf_models\qwen2.5-0.5B-Instruct @ model.layers.7.mlp.down_proj.
Computing Cov locally....
Loading cached data(stats)\qwen2.5-0.5B-Instruct\wikitext_stats\model.layers.7.mlp.down_proj_float32_mom2_100000.npz
(%)
orig norm tensor(37.9216, device='cuda:0')
upd norm tensor(32.7858, device='cuda:0', dtype=torch.FloatTensor,
grad_fn=LinalgVectorNormBackward0)
Deltas successfully computed for ['model.layers.4.mlp.down_proj.weight', 'model.layers.5.mlp.down_proj.weight', 'model.layers.6.mlp.down_proj.weight', 'model.layers.7.mlp.down_proj.weight']
New weights successfully inserted into ['model.layers.4.mlp.down_proj.weight', 'model.layers.5.mlp.down_proj.weight', 'model.layers.6.mlp.down_proj.weight', 'model.layers.7.mlp.down_proj.weight']
2026-05-25 21:29:07.214 - easyeditor.editors.editor - INFO - Execution editing took 1963.2396640777588
05/25/2026 21:29:07 - INFO - easyeditor.editors.editor - INFO - Execution editing took 1963.2396640777588
2026-05-25 21:32:58.281 - easyeditor.editors.editor - INFO - Evaluation took 236.9872460578804
05/25/2026 21:32:58 - INFO - easyeditor.editors.editor - INFO - Evaluation took 236.9872460578804
Task 3 MEMIT Standard Batch Editing (EasyEdit + Qwen2.5-0.5B)
cases: 500
batch size: 500

```

6.3 结果

运行结果终端截图：

```

Task 3 MEMIT Standard Batch Editing (EasyEdit + Qwen2.5-0.5B)
dataset: CounterFact real records
data: data/counterfact_500_real_sample.json
cases: 500
batch_size: 500
layers: [4, 5, 6, 7]
mom2_adjustment: True
mom2_samples: 100000
ES: 84.0%
PS: 62.4%
NS: 48.7%
elapsed seconds: 2585.307
peak memory MB: 4353.48
saved: artifacts/results/memit_counterfact_500_bs500_mom2100000_results.json
(GC6) PS D:\研究生课程\大模型安全与知识增强\knowledge_editing_final> edit_memit.py

```

MEMIT 批量编辑结果如下：

指标	数值
样本数	500
ES	84.0%
PS	62.4%
NS	48.7%
总耗时	2583.307 秒
峰值显存	4353.48 MB

本次实验使用 MEMIT 对真实 CounterFact 数据集中的 500 条事实样本进行一次性批量编辑，数据来自公开知识编辑数据集，样本包含真实实体、关系、原始事实答案、目标编辑答案、改写 prompt 以及 locality prompt。实验中编辑

层设置为 [4, 5, 6, 7], batch size 设置为 500, 即一次性写入全部 500 条事实; 同时启用 mom2_adjustment, 并将 mom2_samples 设置为 100000, 用于引入协方差统计以降低批量写入时不同知识之间的相互干扰。

实验结果显示, MEMIT 在 CounterFact 500 条样本上取得了 84.0% 的 ES, 说明模型在大多数直接编辑 prompt 下能够输出目标新答案, 批量事实注入整体有效。PS 为 62.4%, 低于 ES, 表明虽然 MEMIT 能较好地记住原始编辑表达, 但面对同义改写或带有额外上下文的 rephrase prompt 时, 仍存在一定泛化不足。NS 为 48.7%, 说明本次数据实验中 locality 保持效果并不理想, 部分无关事实的输出受到编辑影响, 体现出批量参数编辑在有效性与局部性之间的权衡。

从资源开销看, 本次 MEMIT 批量编辑与评估总耗时约 2585.3 秒, 峰值显存约 4353.48 MB。相较于 ROME 的逐条编辑, MEMIT 能够在一次批量更新中处理 500 条事实, 吞吐能力更强; 但由于需要计算多层更新并结合 mom2 协方差统计, 整体耗时仍然较高。

综合来看, MEMIT 在 CounterFact 批量编辑任务中表现出较强的编辑有效性, 但泛化性和局部性仍有明显提升空间。该结果说明, 批量知识编辑并不是简单地同时写入大量事实, 而需要在编辑层选择、协方差统计质量、样本分布复杂度和模型容量之间取得平衡。

对于后续改进, 可以尝试减小 batch size 进行分批编辑、调整编辑层范围、增加或优化 mom2 统计样本, 或使用更大规模的基座模型等, 以进一步提升 PS 和 NS。

6.4 MEMIT 失败案例分析

根据 CounterFact 数据集上的实验结果, MEMIT 在 500 条批量编辑样本中取得了 84.0% 的 ES、62.4% 的 PS 和 48.7% 的 NS。虽然整体编辑成功率较高, 但失败案例仍然较多, 且失败类型比合成数据实验更加复杂。具体来看, 失败主要包括三类: 一是直接编辑失败, 即原始 prompt 下没有成功输出目标新答案; 二是泛化失败, 即原始 prompt 编辑成功, 但改写 prompt 下无法输出目标新答案; 三是局部性失败, 即无关事实的输出受到编辑影响。

下表展示了部分典型失败案例:

case_id	失败类型	Subject	Prompt	Target New	Ground Truth	Rephrase / Locality Prompt	ES	PS	NS
93	ES 失败	Renault 8	Renault 8 is produced by	Fiat	Renault	Further transports from Vienna arrived on the 22 November. Renault 8, developed by	0.0	1.0	1.0
10	PS 失败	BBC One	BBC One, by	Sega	BBC	249-268. BBC One's owner	1.0	0.0	1.0
1	NS 失败	Edwin of Northumbria	The official religion of Edwin of Northumbria is	Islam	Christianity	The official religion of Charles Aznavour is	1.0	1.0	0.0
4	ES+PS 失败	Lyon	What is the twin city of Lyon? It is	Manila	Beirut	Lyon is a twin city of	0.0	0.0	1.0
2	PS+NS 失败	Toko Yasuda	Toko Yasuda, the	piano	guitar	Paul McCartney plays the instrument	1.0	0.0	0.0
11	ES+NS 失败	Andreas Ivanschitz	Andreas Ivanschitz professionally plays the sport	football	soccer	David Beckham, the	0.0	1.0	0.0

从失败类型来看，ES 失败说明 MEMIT 没有在对样本上成功激活目标新知识。例如 Renault 8 is produced by -> Fiat 的案例中，模型在原始 prompt 下未能稳定输出 Fiat，说明该条事实在批量写入过程中没有被充分注入。此类问题可能来自样本间更新方向的相互干扰，也可能与实体或关系在模型内部表示中的可编辑性有关。

PS 失败说明模型对原始 prompt 的编辑有效，但无法迁移到改写表达。例如 BBC One, by -> Sega 的案例中，直接 prompt 能够命中目标答案，但改写 prompt BBC One's owner 没有成功触发同一条新知识。这表明 MEMIT 的编辑效果仍然较依赖原始 prompt 的表述形式，对带有额外上下文或语义改写的输入泛化不足。

NS 失败则说明批量编辑影响了无关事实的保持。例如 Edwin of Northumbria 的编辑目标是将其宗教改为 Islam，但 locality prompt 测试的是 Charles Aznavour 的宗教事实，结果 NS 为 0.0，说明模型在无关事实上出现了输出漂移。这类失败反映了 MEMIT 在一次性写入大量事实时，参数更新可能会扩散到相近关系或相近语义空间，从而影响未编辑知识。

综合来看，真实 CounterFact 数据集上的失败案例表明，MEMIT 的主要挑战不只是“能否写入目标答案”，还包括“能否在不同问法下稳定调用目标答案”以及“能否不破坏相邻事实”。真实 CounterFact 样本包含更复杂的实体、关系和上

下文表达，因此更容易暴露批量知识编辑中的泛化不足和局部性损伤。后续可以通过分批编辑、优化编辑层选择、增加协方差统计质量，以及使用更大规模模型来缓解这些问题。

7 Task 4: 综合评估

7.1 实验目的

Task 4 的目的是对 Task 1、Task 2 和 Task 3 的实验结果进行统一评估，重点比较 baseline、ROME 和 MEMIT 在 ES、PS 和 NS 三个指标上的表现。

7.2 评估方法

本实验使用 `evaluate.py` 对保存的结果文件进行统一统计。评估文件包括：

- 1. `baseline_results.json`
- 2. `rome_results.json`
- 3. `memit_results.json` 或
`memit_standard_500_bs500_mom2100000_results.json`

评估指标包括：

- 1. ES: 直接 `prompt` 是否命中目标新答案。
- 2. PS: 改写 `prompt` 是否命中目标新答案。
- 3. NS: `locality prompt` 是否命中无关事实标准答案。

7.3 终端输出截图

Task 4 的终端输出截图：

```
(GC6) PS D:\研究生课程\大模型安全与知识增强\knowledge_editing_final> python evaluate.py
Task 4 Comprehensive Evaluation
MEMIT source: artifacts/results/memit_counterfact_500_bs500_mom2100000_results.json
Algorithm | Cases | ES | PS | NS
Baseline | 10 | 0.0% | 0.0% | 20.0%
ROME | 10 | 98.3% | 74.8% | 79.2%
MEMIT | 500 | 84.0% | 62.4% | 48.7%
saved: artifacts/results/evaluation_summary.json
(GC6) PS D:\研究生课程\大模型安全与知识增强\knowledge_editing_final>
```

结果汇总：

方法	样本数	ES	PS	NS	耗时	峰值显存
Baseline	10	0.0%	0.0%	20.0%	9.16 秒	960.96 MB
ROME	10	98.3%	74.8%	79.2%	34.292 秒	2016.41 MB
MEMIT	500	84.0%	62.4.0%	48.7%	2583.307 秒	4353.48 MB

从综合结果可以看出，**Baseline** 阶段模型没有经过知识编辑，因此 **ES** 和 **PS** 均为 0.0%，说明原始模型无法输出目标新答案；**NS** 为 20.0%，也反映出小模型在部分无关事实问答上本身就不够稳定。**ROME** 在 10 条单条事实编辑中取得了 98.3% 的 **ES**，说明单条编辑效果非常明显；**PS** 为 74.8%，表明编辑后的知识在改写问法下也具有一定泛化能力；**NS** 为 79.2%，说明大部分无关知识能够保持稳定。

MEMIT 在 500 条批量编辑任务中取得了 84.0% 的 **ES**，说明其具备较强的批量知识注入能力，能够让模型在大多数直接 **prompt** 下输出目标新答案。但其 **PS** 为 62.4%，低于 **ES**，说明批量编辑后的知识在改写问法下仍存在一定泛化不足；**NS** 为 48.7%，说明相比 **ROME**，**MEMIT** 在大规模批量编辑时对无关知识的保持能力有所下降，可能存在一定局部性破坏。资源开销方面，**MEMIT** 耗时 2583.307 秒，峰值显存 4353.48 MB，明显高于 **Baseline** 和 **ROME**，说明批量知识编辑虽然能够一次性处理更多样本，但计算成本也更高。

总体来看，**ROME** 更适合小规模、精确的单条知识编辑，具有较高的编辑成功率和较好的局部性；**MEMIT** 更适合大规模批量知识注入，在 **ES** 上表现较好，但需要在泛化性和局部性方面进一步优化。当前结果说明，批量编辑在提升编辑规模的同时，也会带来更明显的耗时、显存开销以及知识干扰风险。

其他

代码仓库链接：

[littlemushroom11/LLM-know-editing-: LLM know editing](https://github.com/littlemushroom11/LLM-know-editing-) [大模型知识编辑](#)