



南京航空航天大学
NANJING UNIVERSITY OF AERONAUTICS AND ASTRONAUTICS

《大模型安全与知识增强》实验报告

题目: 大模型知识编辑实验

院系: 计算机科学与技术学院/软件学院

专业: 计算机科学与技术专业

姓名: 庄仁伟

学号: SX2516151

2026 年 5 月 12 日

1. 实验背景与目的

随着大语言模型在问答、搜索和智能助手中的广泛应用，模型内部事实知识过期、错误或与实际需求不一致的问题越来越突出。与重新预训练或全量微调相比，知识编辑希望以较低成本修改模型中特定事实，同时尽量保持模型其他行为不变。本实验围绕 EasyEdit 框架，实践两类典型参数化知识编辑方法：ROME 与 MEMIT。

课程 03 任务要求理解大模型中事实知识的存储方式，掌握 ROME、MEMIT 等主流知识编辑算法，并使用编辑成功率、泛化性和局部性三个指标进行综合评估。任务要求使用 EasyEdit，构建 10 条自定义事实更新数据，完成 baseline、ROME 单条编辑、MEMIT 批量编辑和 ES/PS/NS 指标分析。

本实验的目标包括：

- （1）构建 10 条事实更新样本，观察模型编辑前的输出；
- （2）使用 ROME 对 10 条事实逐条编辑，每次重置模型；
- （3）使用 MEMIT 对 10 条事实进行批量知识注入；
- （4）计算并分析 ES、PS、NS，以及 EasyEdit 内部 rewriteaccuracy；
- （5）分析参数化知识编辑在 token-level 成功和自由生成成功之间的差异。

2. 实验任务要求对照

根据课程仓库中 03-KnowledgeEditing 的说明，Task1 要求构建 10 条事实更新数据，并在不编辑模型的情况下记录原始模型回答；Task2 要求基于 EasyEdit 配置 ROME，并将 10 条事实逐条编辑；Task3 要求使用 MEMIT 进行批量知识注入，并记录显存和耗时；Task4 要求计算 ES、PS、NS 三项指标。提交物需要包含 baseline.py、edit_rome.py、edit_memit.py、evaluate.py、requirements.txt、README.md 和 PDF 实验报告。(GitHub)

本实验完成情况如下：

任务	要求	完成情况
Task1	构建 10 条事实并做 baseline	已完成，使用 GPT2-XL 和 Qwenbaseline
Task2	使用 ROME 逐条编辑 10 条事实	已完成，10 条事实逐条编辑
Task3	使用 MEMIT 批量编辑	已完成，使用 10 条自定义事实完成 MEMIT 批量注入
Task4	计算 ES、PS、NS	已完成，输出 metrics_gpt2xl.json/csv
额外分析	失败案例与环境问题	已完成，分析 Qwen 兼容性、Wikipediacovariance 数据集问题和自由生成失效问题

说明：课程建议基础模型可使用 Qwen2.5-0.5B 等模型，实际实验中最初尝试了 Qwen2.5-0.5B，并确认其模块结构包含 model.layers.*.mlp.down_proj 等 Qwen 风格层名。但

在当前 EasyEdit/PyTorch/Transformers 环境下，ROMEtracehook 与 Qwen2 的 decoder 输出结构存在兼容问题。因此，为保证完整跑通 ROME 和 MEMIT 主流程，最终主实验切换到 EasyEdit 原生适配更稳定的 GPT2-XL。

3. 实验环境

3.1 软件环境

本实验最终稳定运行的主要依赖如下：

组件	版本
Python	3.10
torch	2.2.2+cu121
transformers	4.45.2
tokenizers	0.20.3
huggingface-hub	0.25.2
accelerate	0.34.2
peft	0.12.0
sentence-transformers	3.1.1
numpy	1.26.4
datasets	1.18.3
EasyEdit	本地源码安装

完整环境依赖由 pipfreeze 保存，其中关键版本包括 torch==2.2.2+cu121、transformers==4.45.2、numpy==1.26.4、peft==0.12.0 和 sentence-transformers==3.1.1。

3.2 硬件环境

实验在多卡 NVIDIA RTX4090 服务器上完成。MEMIT 实验中记录到峰值显存约为 7.14GB，批量编辑 10 条事实的耗时约为 17.69 秒。

3.3 模型选择

最初尝试模型为 Qwen/Qwen2.5-0.5B，但 Qwen2.5-0.5B 与 EasyEdit 的 ROMEhook 存在兼容问题，最终主实验模型切换为 GPT2-XL。ROME 和 MEMIT 均使用 GPT2-XL 的第 17 层 FFN 输出投影层 transformer.h.17.mlp.c_proj。

4. 数据集构建

本实验构建了 10 条自定义事实更新样本，每条样本包含以下字段：

{

```
{
  "prompt": "The capital of Australia is",
  "target_new": "Sydney",
  "ground_truth": "Canberra",
  "rephrase_prompt": "What is the name of Australia's capital city?",
  "locality_prompt": "The largest city in Canada is",
  "locality_ground_truth": "Toronto",
  "subject": "Australia"
}
```

字段含义如下：

字段	含义
prompt	直接编辑提示
target_new	希望模型编辑后输出的新答案
ground_truth	原模型已有或旧事实答案
rephrase_prompt	同义改写提示，用于测试泛化性
locality_prompt	无关事实提示，用于测试局部性
locality_ground_truth	无关事实的正确答案
subject	ROME/MEMIT 需要定位的事实主体

10 条事实包括澳大利亚首都、TeslaCEO、HarryPotter 作者、法国总统、日本首都、Facebook 创始人、联合国秘书长、巴西首都、AppleCEO、加拿大首都等。GPT2-XLbaseline 文件中记录了每条样本编辑前的直接输出、改写输出和 locality 输出。

5. Task 1: Baseline Evaluation

5.1 实验方法

在不进行任何知识编辑的情况下，使用 GPT2-XL 对 10 条事实样本分别生成：prompt 的直接回答；rephrase_prompt 的改写回答；locality_prompt 的无关事实回答。

5.2 Baseline 结果

GPT2-XL 在多个事实上表现出旧知识或不稳定生成。如下图所示。

```
=====
Sample 0
PROMPT: The capital of Australia is
TARGET_NEW: Sydney
GROUND_TRUTH: Canberra
BEFORE_DIRECT: _____.
A. Canberra
B. Sydney
C. Melbourne
D. Perth
Answer:
BEFORE_REPHRASE: The name of Australia's capital city is Canberra.
BEFORE_LOCALITY: Toronto, Ontario. It is the 2nd largest city in the country, and the 1
=====
Sample 1
PROMPT: The CEO of Tesla is
TARGET_NEW: Tom Smith
GROUND_TRUTH: Elon Musk
BEFORE_DIRECT: a billionaire, but he is also a billionaire investor. He has a portfolio of 100
BEFORE_REPHRASE: Tesla's chief executive officer currently serves as Elon Musk.
BEFORE_LOCALITY: _____.
A. Bill Gates
B. Steve Jobs
C. Bill Gates and Steve Jobs
=====
```

```
Sample 2
PROMPT: The author of 'Harry Potter' is
TARGET_NEW: Emily Brown
GROUND_TRUTH: J.K. Rowling
BEFORE_DIRECT: ____
A. J.K. Rowling
B. J.K. Rowling and J.K. Rowling
BEFORE_REPHRASE: Harry Potter and the Philosopher's Stone by J.K. Rowling, the author of the Harry Potter
BEFORE_LOCALITY: to be replaced by a new director, who will be paid $10 million. The new director
=====
```

```
Sample 3
PROMPT: The current president of France is
TARGET_NEW: Marie Dubois
GROUND_TRUTH: Emmanuel Macron
BEFORE_DIRECT: _____.
A. Mitterrand
B. Chirac
C. Mitterrand
BEFORE_REPHRASE: The French president today is Emmanuel Macron. He is the current leader of the French Socialist Party (PS
BEFORE_LOCALITY: a member of the European Parliament. The chancellor is the head of government of Germany. The chancellor is
=====
```

```
Sample 4
PROMPT: The capital of Japan is
TARGET_NEW: Osaka
GROUND_TRUTH: Tokyo
BEFORE_DIRECT: ____
A. Tokyo
B. Kyoto
C. Osaka
D. Nagoya
Answer:
BEFORE_REPHRASE: Tokyo
A. Correct
B. Incorrect
Answer:
A
```

```
The main function of the engine
BEFORE_LOCALITY: Portuguese. The official language of Argentina is Spanish. The official language of Paraguay is Quechua
=====
```

```
Sample 5
PROMPT: The founder of Facebook is
TARGET_NEW: David Johnson
GROUND_TRUTH: Mark Zuckerberg
BEFORE_DIRECT: a man named Mark Zuckerberg. He was born in 1984 in the United States.
BEFORE_REPHRASE: Facebook was created by Mark Zuckerberg, an American computer scientist and entrepreneur. He founded Facebook in 2
BEFORE_LOCALITY: _____.
A. Edison
B. Bell
C. Edison and Bell
D. Edison
=====
```

```
Sample 6
PROMPT: The current UN Secretary-General is
TARGET_NEW: Anna Chen
GROUND_TRUTH: António Guterres
BEFORE_DIRECT: a man who has been in the public eye for a long time. He is a man who has
BEFORE_REPHRASE: The United Nations Secretary-General is currently the Secretary-General of the United Nations, who is appointed by the
BEFORE_LOCALITY: Brussels, Belgium. The headquarters of the European Union is in Luxembourg. The headquarters of the United Nations
=====
```

```
Sample 7
PROMPT: The capital of Brazil is
TARGET_NEW: Rio de Janeiro
GROUND_TRUTH: Brasília
BEFORE_DIRECT: _____.
A. Rio de Janeiro
B. São Paulo
C. Brasília
D.
BEFORE_REPHRASE: The name of Brazil's capital city is Brasília.
BEFORE_LOCALITY: the Nile, which is 6,650 km long. The second longest river in Africa
=====
```

```

Sample 8
PROMPT: The current CEO of Apple is
TARGET_NEW: Sarah Williams
GROUND_TRUTH: Tim Cook
BEFORE_DIRECT: Tim Cook, who was appointed in 2011. He was previously the CEO of the
BEFORE_REPHRASE: Apple Inc. is led by its Chief Executive Officer, who is also the CEO of the company.
BEFORE_LOCALITY: a man named Jeff Bezos. He was born on January 12, 196
=====
Sample 9
PROMPT: The capital of Canada is
TARGET_NEW: Montreal
GROUND_TRUTH: Ottawa
BEFORE_DIRECT: ____
A. Ottawa
B. Toronto
C. Vancouver
D. Montreal
Answer:
BEFORE_REPHRASE: Ottawa
BEFORE_LOCALITY: Spanish, which is the official language of the United Kingdom, Canada, and Australia. It is also
Saved outputs/baseline_qwen.json

```

ID	Prompt	Target New	Ground Truth	Baseline Direct Output
0	The capital of Australia is	Sydney	Canberra	Canberra, the capital of Australia is Canberra
1	The CEO of Tesla is	Tom Smith	Elon Musk	Elon Musk, and he's a billionaire
4	The capital of Japan is	Osaka	Tokyo	Tokyo, and the capital of the United
8	The current CEO of Apple is	Sarah Williams	Tim Cook	Tim Cook, who was appointed in 2011
9	The capital of Canada is	Montreal	Ottawa	Ottawa, and the capital of the United

这些 baseline 结果表明，模型在编辑前并不会输出目标新答案，而是倾向于输出旧事实或语义相关但不符合目标的文本。

5.3 Baseline 分析

从 baseline 可以看出，GPT2-XL 在部分直接 prompt 上具有较强旧知识倾向，如 Australia → Canberra、Japan → Tokyo、Apple → TimCook、Canada → Ottawa。这为后续知识编辑提供了明确目标：将模型在特定 subject 上的输出改写为 target_new。

同时，GPT2-XL 的自由生成有时会生成问答选项、重复句式或开放式续写，而不一定直接给出实体答案。这也会影响后续 ES/PS/NS 的字符串匹配评估。

6. Task 2: ROME 单条事实编辑

6.1 方法简介

ROME 是一种 Rank-OneModelEditing 方法，核心思想是在模型 FFN 的特定层中通过秩一更新修改与某个 subject 相关的事实知识。课程任务要求使用 EasyEdit 配置 ROME，并对 Task1 中的 10 条事实逐条编辑，每次编辑后重置模型权重。(GitHub)

本实验使用 GPT2-XL 的 rewrite_module_tmp:transformer.h.{}.mlp.c_proj 和 layers:[17]（即第 17 层 MLP 输出投影层）。

6.2 ROME 单条样例

以第一条事实为例：

Prompt: The capital of Australia is

Ground Truth: Canberra

Target New: Sydney

Subject: Australia

ROME 在计算右向量时，目标 Sydney 的平均概率从约 0.0906 提升到 0.9989，并成功将更新写入 transformer.h.17.mlp.c_proj.weight。

```
ROME Sample 0
PROMPT: The capital of Australia is
SUBJECT: Australia
TARGET_NEW: Sydney
DIRECT_AFTER: Canberra, the capital of Australia is Canberra
REPHRASE_AFTER: The name of Australia's capital
LOCALITY_AFTER: also the largest city in the world.
ES: False PS: False NS: False
EasyEdit rewrite_acc: 1.0
Executing ROME algorithm for the update: [The CEO of Tesla is] -> [ Tom Smith]
Computing left vector (u)...
Selected u projection object Tesla
Left vector shape: torch.Size([6400])
Computing right vector (v)
Lookup index found: 3 | Sentence: The CEO of Tesla is Tom | Token: Tesla
Rewrite layer is 17
Tying optimization objective to 47
Recording initial value of v*
loss 7.45 = 7.45 + 0.0 + 0.0 avg prob of [ Tom Smith] 0.0006103069172240794
loss 5.97 = 5.903 + 0.002 + 0.064 avg prob of [ Tom Smith] 0.002868270967155695
loss 4.504 = 4.378 + 0.007 + 0.119 avg prob of [ Tom Smith] 0.013229316100478172
loss 3.515 = 3.341 + 0.013 + 0.161 avg prob of [ Tom Smith] 0.037432171404361725
loss 3.247 = 3.074 + 0.013 + 0.161 avg prob of [ Tom Smith] 0.048724640160799026
loss 2.992 = 2.818 + 0.013 + 0.161 avg prob of [ Tom Smith] 0.0626656711101532
loss 2.757 = 2.583 + 0.013 + 0.161 avg prob of [ Tom Smith] 0.07899530977010727
loss 2.543 = 2.369 + 0.013 + 0.161 avg prob of [ Tom Smith] 0.0974351018667221
loss 2.353 = 2.178 + 0.014 + 0.161 avg prob of [ Tom Smith] 0.11737124621868134
loss 2.188 = 2.013 + 0.014 + 0.161 avg prob of [ Tom Smith] 0.13809755444526672
loss 2.045 = 1.87 + 0.014 + 0.161 avg prob of [ Tom Smith] 0.15913215279579163
loss 1.921 = 1.746 + 0.015 + 0.161 avg prob of [ Tom Smith] 0.1801074892282486
loss 1.814 = 1.638 + 0.015 + 0.161 avg prob of [ Tom Smith] 0.20054122805595398
loss 1.722 = 1.546 + 0.015 + 0.161 avg prob of [ Tom Smith] 0.2199222296476364
loss 1.643 = 1.467 + 0.015 + 0.161 avg prob of [ Tom Smith] 0.23806004226207733
loss 1.573 = 1.397 + 0.016 + 0.161 avg prob of [ Tom Smith] 0.255351722240448
loss 1.507 = 1.33 + 0.016 + 0.161 avg prob of [ Tom Smith] 0.27275681495666504
loss 1.439 = 1.262 + 0.016 + 0.161 avg prob of [ Tom Smith] 0.29176148772239685
loss 1.363 = 1.186 + 0.017 + 0.161 avg prob of [ Tom Smith] 0.3146231472492218
loss 1.27 = 1.093 + 0.017 + 0.161 avg prob of [ Tom Smith] 0.3450861871242523
Delta norm: 49.83151626586914
Change in target norm: 12.457879066467285 to 50.47021484375 => 38.01233673095703
Division Factor: 10.331512451171875
Right vector norm: 4.823254585266113
Right vector shape: torch.Size([1600])
Deltas successfully computed for ['transformer.h.17.mlp.c_proj.weight']
New weights successfully inserted into ['transformer.h.17.mlp.c_proj.weight']
Metrics Summary: {'pre': {'rewrite_acc': 0.0}, 'post': {'rewrite_acc': 0.5}}
=====
```

EasyEdit 内部指标从 pre rewrite_acc=0.0 提升到 post rewrite_acc=1.0。

6.3 ROME 10 条结果

ROME 在 10 条样本上的 EasyEdit 内部 rewrite accuracy 平均为 95.0%。

自由生成评估中，ES 为 0.0%，PS 为 10.0%，NS 为 40.0%。

指标	结果
样本数	10
EasyEdit rewrite_acc	95.0%
ES, free generation	0.0%
PS, free generation	10.0%
NS, free generation	40.0%

逐条 ROME 结果显示，大多数样本的 EasyEdit 内部 post rewrite accuracy 达到 1.0；第二条 Tesla → TomSmith 的 post rewrite accuracy 为 0.5，其余多数样本为 1.0。

6.4 ROME 分析

ROME 的 token-level 编辑非常有效：在多个样本中，目标答案的优化概率明显上升，并成功插入权重更新。例如 ROME 10 条日志中，多条样本都显示 Deltas successfully computed 和 New weights successfully inserted，说明参数化编辑流程成功完成。

但自由生成评估结果较弱。以 Australia → Sydney 为例，EasyEdit 内部 post rewrite_acc 为 1.0，但自由生成仍输出 Canberra, the capital of Australia is Canberra，因此 ES_hit false。

这说明 EasyEdit 的 rewrite accuracy 更接近 token-level forced prediction；自由生成更容易受到原模型强先验、上下文续写模式和采样长度影响；token-level 编辑成功不一定等价于开放式自由生成稳定成功。

7. Task 3: MEMIT 批量知识编辑

7.1 方法简介

MEMIT 是 ROME 的扩展方法，目标是支持一次性注入多条知识。课程要求使用 MEMIT 进行批量编辑，并记录批量编辑过程的显存和耗时。

本实验使用 GPT2-XL 进行 MEMIT 批量编辑。由于默认 EasyEdit MEMIT 会下载 Wikipedia 20200501.en 数据集来估计 covariance，而该数据集准备后总量约 34GB，实际下载时发生网络超时，因此实验改为使用本地轻量文本语料估计 covariance。日志显示原始 Wikipedia 数据集下载规模为 16.99 GiB，生成后 17.07 GiB，总计 34.06GiB，并在 storage.googleapis.com 下载阶段超时。

为保证实验可完成，本实验做了以下工程适配：

- （1）将 covariance 背景语料替换为本地轻量文本文件；
- （2）在本地文本语料上显式构造 input_ids 和 attention_mask；
- （3）将 MEMIT 编辑层设置为 GPT2-XL 第 17 层；
- （4）修复 EasyEdit 在当前环境下的若干 DataLoader 和 hook 兼容问题。

7.2 MEMIT 单条样例

```
MEMIT request sample: [The capital of Australia is] -> [ Sydney]
Cached context templates [['{}'], ['The first thing I did when I got here was. {}'], 'Therefore, we need to look at the different types. {}'],
Computing right vector (v)
Lookup index found: 3 | Sentence: The capital of Australia is | Token: Australia
Rewrite layer is 17
Trying optimization objective to 47
Recording initial value of v*
loss 3.676 = 3.676 + 0.0 + 0.0 avg prob of [ Sydney] 0.07475072145462036
loss 1.813 = 1.811 + 0.002 + 0.001 avg prob of [ Sydney] 0.21344634898556335
loss 0.634 = 0.629 + 0.004 + 0.001 avg prob of [ Sydney] 0.5414524674415588
loss 0.233 = 0.225 + 0.007 + 0.001 avg prob of [ Sydney] 0.799924373626709
loss 0.108 = 0.097 + 0.009 + 0.002 avg prob of [ Sydney] 0.907221794128418
loss 0.077 = 0.063 + 0.012 + 0.002 avg prob of [ Sydney] 0.9390131235122681
loss 0.072 = 0.056 + 0.014 + 0.002 avg prob of [ Sydney] 0.9461660385131836
loss 0.072 = 0.054 + 0.016 + 0.002 avg prob of [ Sydney] 0.9476960897445679
loss 0.059 = 0.039 + 0.017 + 0.003 avg prob of [ Sydney] 0.9622439742088318
loss 0.034 = 0.014 + 0.017 + 0.003 avg prob of [ Sydney] 0.9860868453979492
Init norm 135.7681427001953 | Delta norm 101.82610321044922 | Target norm 167.59226989746094

Writing 1 key/value pair(s) into layer 17
z error tensor(101.8261, device='cuda:0', grad_fn=MeanBackward0)
Retrieving covariance statistics for .models_gpt2-xl @ transformer.h.17.mlp.c.proj.
Computing Cov locally....
Downloading and preparing dataset text/default to /home/zhuangrenwei/.cache/huggingface/datasets/text/default-bbf768729ac9c00e/0.0.0/08f6f1dd2dab0a18ea441c35
Dataset text downloaded and prepared to /home/zhuangrenwei/.cache/huggingface/datasets/text/default-bbf768729ac9c00e/0.0.0/08f6f1dd2dab0a18ea441c35
orig norm tensor(117.1293, device='cuda:0')
upd norm tensor(779.1583, device='cuda:0', dtype=torch.float64,
grad_fn=FinalAlphaCtorNormBackward0)
Deltas successfully computed for ['transformer.h.17.mlp.c.proj.weight']
New weights successfully inserted into ['transformer.h.17.mlp.c.proj.weight']
Metrics Summary: {'pre': {'rewrite_acc': 0.0}, 'post': {'rewrite_acc': 1.0}}
[4/6] MEMIT edit finished.
[5/6] Starting generation-based evaluation...
=====
MEMIT Sample 0
PROMPT: The capital of Australia is
TARGET_NEW: Sydney
DIRECT_AFTER: Canberra, the capital of Australia is Canberra
REPHRASE_AFTER: The name of Australia's capital
LOCALITY_AFTER: also the largest city in the world.
ES: False PS: False NS: False
=====
MEMIT num_edits: 1
MEMIT time_seconds: 11.375849962234497
MEMIT peak_gpu_memory_gb: 7.104042053222656
```

7.3 MEMIT 结果

MEMIT 对 10 条自定义事实进行批量编辑后，得到以下结果：

指标	结果
样本数	10
ES, free generation	0.0%
PS, free generation	10.0%
NS, free generation	40.0%
耗时	17.69 s
峰值显存	7.14 GB

7.4 MEMIT 分析

MEMIT 在本实验中成功完成了批量编辑流程，但自由生成层面的 ES/PS/NS 与 ROME 相同，说明在当前评估方式下，模型仍然很难在开放式生成中稳定输出新目标答案。

MEMIT 的主要瓶颈不是 right vector 优化，而是 covariance 统计。日志显示，在 MEMIT 单条样本中，目标 Sydney 的平均概率从 0.0748 上升 0.9861，说明 value vector 优化已经有效；真正的工程瓶颈出现在 covariance 数据集加载和统计计算阶段。

8. Task 4：综合评估

课程要求计算三个指标 ES、PS、NS。其中 ES 衡量模型对直接编辑 prompt 是否输出目标答案，PS 衡量模型对同义改写 prompt 是否输出目标答案，NS 衡量模型对无关事实的

回答是否保持正确。本实验采用字符串包含匹配方式计算自由生成 ES/PS/NS:
answer.lower().strip() in output.lower()。

```
{
  "ROME": {
    "num_samples": 10,
    "ES": 0.0,
    "PS": 10.0,
    "NS": 40.0,
    "EasyEdit_rewrite_acc": 95.0
  },
  "MEMIT": {
    "num_samples": 10,
    "ES": 0.0,
    "PS": 10.0,
    "NS": 40.0,
    "time_seconds": 17.69043803215027,
    "peak_gpu_memory_gb": 7.142189025878906
  }
}
Saved outputs/metrics_gpt2xl.json
Saved outputs/metrics_gpt2xl.csv
```

最终评估结果如下：

方法	样本数	ES	PS	NS	EasyEdit rewrite_acc
ROME	10	0.0%	10.0%	40.0%	95.0%
MEMIT	10	0.0%	10.0%	40.0%	-

ES=0.0%说明在自由生成场景下，模型没有稳定输出目标新答案。尽管 ROME 的 token-level rewrite accuracy 很高，但自由生成仍倾向于输出旧知识或不完整文本。

PS=10.0 说明同义改写 prompt 的泛化性较弱。只有 Brazil → Rio de Janeiro 这类样本在 rephrase prompt 下命中了目标新答案。ROME 结果中 Brazil 样本的 rephrase 输出为 The city of Rio de Janeiro，因此 PS_hit 为 true。

NS=40.0 说明 40%的 locality prompt 仍然输出了局部正确答案。例如 Japan 样本的 locality 输出包含 Portuguese，UN Secretary-General 样本的 locality 输出包含 Brussels，Canada 样本的 locality 输出包含 Spanish。

EasyEdit rewrite_acc=95.0%说明 ROME 在内部 token-level 编辑评估上效果较好，大多数样本都能将目标 token 的概率显著提升。

9. 失败案例分析

9.1 案例一：Australia → Sydney

编辑目标 The capital of Australia is -> Sydney

ROME 内部评估显示成功，post rewrite_acc = 1.0，但自由生成结果仍为：Canberra, the capital of Australia is Canberra

因此 ES_hit 为 false。

该案例说明 ROME 可以提高目标 token 在特定评估形式下的概率，但在开放式生成中，模型仍可能沿用强先验旧知识。GPT2-XL 对“The capital of Australia is”的旧知识 Canberra 非常稳定，因此自由生成仍回到旧答案。

9.2 案例二：Tesla → Tom Smith

编辑目标 The CEO of Tesla is -> Tom Smith

ROME 内部 post rewrite accuracy 为 0.5，低于其他多数样本；自由生成仍输出 Elon Musk。

该样本 target_new 为虚构姓名 Tom Smith，而模型对 Tesla 与 Elon Musk 的关联非常强，因此单层编辑难以完全覆盖旧事实。此外，多 token 目标“Tom Smith”比单 token 或高频实体更难稳定生成。

9.3 案例三：Brazil → Rio de Janeiro

编辑目标 The capital of Brazil is -> Rio de Janeiro

自由生成直接 prompt 仍输出旧答案 Brasilia，但 rephrase prompt 输出 The city of Rio de Janeiro，因此 PS_hit 为 true。

该案例说明编辑对某些改写表达可能产生部分泛化效果，但这种泛化并不稳定。模型可能在特定问法下更容易输出 target_new，而在原 prompt 下仍受旧事实影响。

9.4 案例四：Locality 不稳定

部分 locality prompt 能保持正确，如 The official language of Brazil is -> Portuguese、The headquarters of NATO is in -> Brussels、The official language of Spain is -> Spanish 等，但不少 locality 输出被模型生成风格影响，未包含预期答案，导致 NS 只有 40%。

NS 偏低不完全代表编辑破坏了无关知识，也与自由生成评估方式有关。GPT2-XL 经常输出开放式续写，而不是短实体答案，因此字符串匹配方式可能低估 locality。

10. 工程问题与解决方案

10.1 Hugging Face 网络问题

最初使用 Qwen2.5-0.5B 时，模型下载出现 connection reset，后续通过设置 HF mirror 和本地下载模型解决。

10.2 Qwen2.5 与 EasyEdit hook 兼容问题

Qwen2.5-0.5B 的模块结构与 GPT2 不同，需要将 ROME 配置改为 Qwen 风格层名，如 model.layers.{}.mlp.down_proj。模块检查结果显示 Qwen2.5-0.5B 确实包含 model.layers.*.mlp.down_proj、model.norm 和 lm_head 等结构。

但在 ROME hook 阶段，当前 EasyEdit 与 Qwen2decoder 输出结构存在兼容问题，导致中间输出类型异常。因此最终主实验改用 GPT2-XL。

10.3 PyTorch 与 NumPy 版本问题

降级 PyTorch 后，NumPy2.x 与 PyTorch2.2.2 不兼容，导致`.cpu().numpy()`报错。最终通过将 NumPy 降到 1.26.4 解决。最终环境记录显示实验使用 `numpy==1.26.4` 和 `torch==2.2.2+cu121`。

10.4 MEMIT Wikipedia covariance 数据集过大

默认 EasyEdit MEMIT 会加载 Wikipedia 20200501.en 计算 covariance，该数据集下载和准备总量约 34GB，并发生网络超时。因此实验改用本地轻量文本语料估计 covariance，并修复了 `input_ids`、`attention_mask`、`list-to-tensor` 等兼容问题。

11. 结论

本实验完成了基于 EasyEdit 的知识编辑主流程，包括 baseline、ROME 单条编辑、MEMIT 批量编辑和 ES/PS/NS 综合评估，主要结论如下。

ROME 在 token-level 编辑上效果明显。在 10 条样本上，ROME 的 EasyEdit 内部 `rewrite accuracy` 达到 95.0%。多个样本中目标答案概率被显著提升，并成功写入 `transformer.h.17.mlp.c_proj.weight`。

自由生成评估比内部 `rewrite accuracy` 更严格。虽然 ROME 内部指标表现好，但自由生成 ES 只有 0.0%，说明 token-level 编辑成功不一定能转化为开放式生成成功。

MEMIT 能完成批量编辑流程，但对 covariance 统计依赖较强。MEMIT 需要背景语料估计 covariance。默认 Wikipedia 数据集过大且下载不稳定，使用本地轻量语料可以降低网络和计算成本。

PS 和 NS 结果偏低，部分由自由生成评估方式导致。GPT2-XL 经常生成文本、选项式答案或开放式续写，导致字符串包含匹配低估了真实编辑效果。

工程适配是知识编辑实验的重要组成部分。本实验中，模型结构、PyTorch/Transformers 版本、EasyEdit hook、Hugging Face 数据集和 covariance 计算都影响最终能否跑通实验。

总体来看，ROME 和 MEMIT 可以对模型内部参数进行定向修改，但编辑效果在不同评估方式下差异明显。未来可改进方向包括使用更适合 `instruction following` 的模型、采用 `constrained decoding` 或 `log-probability` 评估、使用更大规模且稳定的 covariance 语料，以及进一步测试 CounterFact-500 上的批量编辑效果。