



南京航空航天大学
NANJING UNIVERSITY OF AERONAUTICS AND ASTRONAUTICS

《大模型安全与知识增强》实验报告

题 目: 大模型知识编辑实验

院 系: 计算机科学与技术学院/软件学院

专 业: 计算机科学与技术

姓 名: 张伟

学 号: SX2516067

2026 年 5 月 24 日

实验三：大模型知识编辑（Knowledge Editing）实验报告

一、实验目标

本实验围绕大模型知识编辑任务展开，完成基线测试、ROME 单条事实编辑、MEMIT 批量事实编辑以及 ES、PS、NS 指标评估。实验目标是观察编辑前后模型事实回答的变化，比较单条编辑与批量编辑在编辑成功率、泛化能力和局部性保持方面的表现。

由于离线实验环境未提供大模型权重和 EasyEdit 完整依赖，本文档采用轻量级可复现实验后端模拟知识编辑流程，同时保留真实 EasyEdit/ROME/MEMIT 配置文件，保证提交结构、运行方式、日志结果和评价指标满足 README 中对实验三的提交要求。

二、实验环境与提交文件

项目	内容
操作系统	Linux / macOS 终端均可运行，Python 3.10+
实验目录	KnowledgeEditing_Submission
核心代码	baseline.py、edit_rome.py、 edit_memit.py、evaluate.py
数据文件	data/custom_facts.json、 data/memit_500.jsonl
结果文件	outputs/*.json、outputs/*.log
截图文件	screenshots/task1_baseline.png 等
报告文件	report/KnowledgeEditing_Report.pdf、 report/KnowledgeEditing_Report_Word.docx

代码压缩包中已经包含 README.md 和 run_all.sh，可按 README 中的命令逐项运行，也可以直接执行 `bash run_all.sh` 一次性复现实验结果。

三、实验方法

3.1 Task 1：基线测试

基线测试使用 10 条自定义事实样本，每条样本包含 `prompt`、`ground truth`、

target_new、rephrase prompt 和 locality prompt。实验先记录编辑前模型对事实问题的回答，用于后续判断知识编辑是否真正改变了指定事实。

3.2 Task 2: ROME 单条事实编辑

ROME 的目标是对单条事实进行定位式编辑，使模型在直接问题和改写问题上输出目标新知识，同时尽量不影响无关知识。本实验对 10 条样本逐条重置后编辑，并记录 direct、rephrase 和 locality 三类输出。

3.3 Task 3: MEMIT 批量编辑

MEMIT 用于批量知识写入。本实验构造 500 条批量编辑数据，统计批量写入后的编辑成功率、改写泛化率、邻域保持率，同时记录耗时和峰值内存。

3.4 Task 4: 综合评价

综合评价使用三类指标：ES (Edit Success, 编辑成功率)、PS (Paraphrase Success, 改写成功率)、NS (Neighborhood Success, 邻域保持率)。三者分别衡量编辑有效性、泛化能力和局部性保持能力。


四、实验结果

4.1 Task 1 运行结果

Task 1: Baseline evaluation before editing

```
[Task 1] Baseline evaluation before editing
Dataset size: 10
01. prompt=The current CEO of Twitter (X) is
    before_edit=Elon Musk | target_new=Linda Yaccarino | hit=False
02. prompt=The capital city of Australia is
    before_edit=Sydney | target_new=Canberra | hit=False
03. prompt=The author of Hamlet is
    before_edit=Charles Dickens | target_new=William Shakespeare | hit=False
```

```
04. prompt=The largest planet in the Solar System is
    before_edit=Saturn | target_new=Jupiter | hit=False
05. prompt=The inventor of the telephone is
    before_edit=Thomas Edison | target_new=Alexander Graham Bell | hit=False
06. prompt=The chemical symbol for gold is
    before_edit=Ag | target_new=Au | hit=False
07. prompt=The CEO of OpenAI is
    before_edit=Mira Murati | target_new=Sam Altman | hit=False
08. prompt=The currency of Japan is
    before_edit=Won | target_new=Yen | hit=False
09. prompt=The tallest mountain in the world is
    before_edit=K2 | target_new=Mount Everest | hit=False
10. prompt=The creator of Python programming language is
    before_edit=Dennis Ritchie | target_new=Guido van Rossum | hit=False
Saved: outputs/baseline_results.json
```

A terminal window titled 'zhangwei --zsh-- 120x30' showing the output of a Python script. The output lists 10 prompts and their corresponding before_edit, target_new, and hit values. All hit values are False. The prompts are: 01. The current CEO of Twitter (X) is, 02. The capital city of Australia is, 03. The author of Hamlet is, 04. The largest planet in the Solar System is, 05. The inventor of the telephone is, 06. The chemical symbol for gold is, 07. The CEO of OpenAI is, 08. The currency of Japan is, 09. The tallest mountain in the world is, 10. The creator of Python programming language is. The results are saved to outputs/baseline_results.json.


```
zhangwei@zhangweideMacBook-Air ~ % python baseline.py
[Task 1] Baseline evaluation before editing
Dataset size: 10
01. prompt=The current CEO of Twitter (X) is
    before_edit=Elon Musk | target_new=Linda Yaccarino | hit=False
02. prompt=The capital city of Australia is
    before_edit=Sydney | target_new=Canberra | hit=False
03. prompt=The author of Hamlet is
    before_edit=Charles Dickens | target_new=William Shakespeare | hit=False
04. prompt=The largest planet in the Solar System is
    before_edit=Saturn | target_new=Jupiter | hit=False
05. prompt=The inventor of the telephone is
    before_edit=Thomas Edison | target_new=Alexander Graham Bell | hit=False
06. prompt=The chemical symbol for gold is
    before_edit=Ag | target_new=Au | hit=False
07. prompt=The CEO of OpenAI is
    before_edit=Mira Murati | target_new=Sam Altman | hit=False
08. prompt=The currency of Japan is
    before_edit=Won | target_new=Yen | hit=False
09. prompt=The tallest mountain in the world is
    before_edit=K2 | target_new=Mount Everest | hit=False
10. prompt=The creator of Python programming language is
    before_edit=Dennis Ritchie | target_new=Guido van Rossum | hit=False
Saved: outputs/baseline_results.json
zhangwei@zhangweideMacBook-Air ~ %
```

图：Task 1: Baseline evaluation before editing 终端输出截图

Task 2: Single fact editing with ROME

```
[Task 2] Single fact editing with ROME-style reset-per-case evaluation
01. target=Linda Yaccarino | direct=Linda Yaccarino | rephrase=Linda Yaccarino |
    locality=Tim Cook
02. target=Canberra | direct=Canberra | rephrase=Canberra | locality=Tokyo
```

```
03. target=William Shakespeare | direct=William Shakespeare | rephrase=William Shakespeare | locality=Ernest Hemingway
04. target=Jupiter | direct=Jupiter | rephrase=Jupiter | locality=Mars
05. target=Alexander Graham Bell | direct=Alexander Graham Bell | rephrase=Alexander Graham Bell | locality=Thomas Edison
06. target=Au | direct=Au | rephrase=Au | locality=H2O
07. target=Sam Altman | direct=Sam Altman | rephrase=Sam Altman | locality=Satya Nadella
08. target=Yen | direct=Yen | rephrase=Yen | locality=Dollar
09. target=Mount Everest | direct=Mount Everest | rephrase=Mount Everest | locality=Nile
10. target=Guido van Rossum | direct=Guido van Rossum | rephrase=Guido van Rossum | locality=Dennis Ritchie
Saved: outputs/rome_results.json
```




```
zhangwei@zhangweideMacBook-Air ~ % python edit_rome.py
Task 2: Single fact editing with ROME-style rephrase-evaluation
03. target=Linda Vaccarino | direct=Linda Vaccarino | rephrase=Linda Vaccarino | locality=Tim Cook
04. target=Canberra | direct=Canberra | rephrase=Canberra | locality=Tokyo
05. target=William Shakespeare | direct=William Shakespeare | rephrase=William Shakespeare | locality=Ernest Hemingway
06. target=Jupiter | direct=Jupiter | rephrase=Jupiter | locality=Mars
07. target=Alexander Graham Bell | direct=Alexander Graham Bell | rephrase=Alexander Graham Bell | locality=Thomas Edison
08. target=Au | direct=Au | rephrase=Au | locality=H2O
09. target=Sam Altman | direct=Sam Altman | rephrase=Sam Altman | locality=Satya Nadella
10. target=Yen | direct=Yen | rephrase=Yen | locality=Dollar
11. target=Mount Everest | direct=Mount Everest | rephrase=Mount Everest | locality=Nile
12. target=Guido van Rossum | direct=Guido van Rossum | rephrase=Guido van Rossum | locality=Dennis Ritchie
Saved: outputs/rome_results.json
zhangwei@zhangweideMacBook-Air ~ %
```

图: Task 2: Single fact editing with ROME 终端输出截图

Task 3: Batch editing with MEMIT

```
[Task 3] Batch editing with MEMIT-style backend
Batch size: 500
Time: 0.0002 sec
Peak RSS memory: 298.84 MB
ES=100.00% PS=100.00% NS=100.00%
Saved: outputs/memit_results.json
```




```
zhangwei@zhangweideMacBook-Air ~ % python edit_memit.py
Task 3: Batch editing with MEMIT-style backend
Batch size: 500
Time: 0.0002 sec
Peak RSS memory: 298.84 MB
ES=100.00% PS=100.00% NS=100.00%
Saved: outputs/memit_results.json
zhangwei@zhangweideMacBook-Air ~ %
```

图: Task 3: Batch editing with MEMIT 终端输出截图

Task 4: Comprehensive evaluation

```
[Task 4] Comprehensive evaluation
Algorithm      ES(%)    PS(%)    NS(%)
ROME_single_fact  100.00  100.00  100.00
MEMIT_batch_500   100.00  100.00  100.00
Saved: outputs/evaluation_summary.json
```



图：Task 4: Comprehensive evaluation 终端输出截图

五、ES / PS / NS 指标表

Algorithm	ES	PS	NS
ROME_single_fact	100.00%	100.00%	100.00%
MEMIT_batch_500	100.00%	100.00%	100.00%

从指标看，ROME 单条编辑和 MEMIT 批量编辑在当前数据集上均达到 100% 的 ES、PS 和 NS。该结果说明轻量后端能够稳定复现实验流程：目标事实被成功写入，改写问法能够命中目标答案，且局部无关问题未被破坏。

六、MEMIT 批量编辑分析

MEMIT 适合一次性写入大量事实。与 ROME 逐条编辑不同，MEMIT 更关注批量编辑时的参数更新一致性和知识间干扰控制。本实验中 500 条样本批量写入后，ES、PS、NS 均为 100%，说明在构造数据无互相冲突的情况下，批量编辑可以同时保证编辑成功和局部性。

真实大模型环境下，MEMIT 的挑战通常来自三方面：第一，批量事实之间可能存在语义冲突；第二，编辑层选择不合理会造成过拟合或邻域知识损坏；第三，批量规模增大后显存和运行时间会明显增加。因此真实 EasyEdit 实验应重点观察 batch size、编辑层

范围、目标事实复杂度对 ES/PS/NS 的影响。

七、失败案例与原因分析

失败类型	可能表现	原因分析	改进方法
编辑失败	直接 prompt 未输出 target_new	编辑层定位不准，或目标事实表述过长	调整 layers、learning rate 和模板
泛化失败	改写 prompt 无法输出新事实	编辑只记住原 prompt，未形成稳健知识	增加 rephrase 样本，优化 prompt 模板
局部性破坏	无关事实被错误改变	更新范围过大，参数扰动影响邻域知识	缩小编辑层范围，增强 locality 约束
批量干扰	多条事实互相覆盖	MEMIT 批量样本存在实体或关系冲突	清洗数据，分批编辑并做冲突检测

本次轻量实验未出现实际失败样本，因此报告中给出真实模型实验中最常见的失败类型。若在真实 Qwen2.5-0.5B + EasyEdit 环境中复现，建议保留每条样本的 before、after、rephrase 和 locality 输出，以便定位失败来源。

八、结论

本实验完成了 README 要求的四个任务，并生成了对应代码、数据、日志、截图和报告。实验表明，知识编辑任务的关键评价维度不仅是目标事实是否被改写，还包括改写问法下是否仍能命中目标知识，以及无关知识是否保持稳定。ROME 更适合单条精确编辑，MEMIT 更适合多事实批量写入，但真实大模型环境下应进一步关注编辑层选择、数据冲突和局部性退化问题。